人工智能与机器学习基础
HW1：线性模型、正则化与性能评估

参考解答

中国科学技术大学

2026 年秋季学期

1 学习任务与评估方案

某工厂希望在设备启动前，根据启动前的传感器读数预测本次运行的总耗电量，并将系统用于此前未采集过数据的新设备。现有数据来自同一型号的 60 台设备，每台设备有多次运行记录，记录含设备编号、启动前传感器读数和实际总耗电量。本题只需简要文字说明。

（1）判断该任务属于哪类机器学习任务，并写出模型的输入和输出。

参考解答 这是监督学习中的回归任务。每条记录同时提供启动前可观测的输入和实际总耗电量这一标签，因而属于监督学习；目标是预测数值大小，因而属于回归。输入为启动前传感器读数组成的特征，输出为本次运行的总耗电量。设备编号可用于组织数据，但题目所述预测输入是传感器读数。

（2）某同学将全部运行记录随机划分为训练集和测试集。针对“用于新设备”的目标，指出这一划分方式的主要问题，并给出修正办法。

参考解答 按运行记录随机划分，可能把同一台设备的一部分记录放入训练集，另一部分放入测试集。模型已在训练时接触过这些设备的运行模式，测试结果主要反映对已有设备的新记录的预测能力，未充分检验对未见设备的预测能力。

修正办法是以设备为划分单位：先将设备编号划分成互不重叠的训练设备集合和测试设备集合，再将每台设备的全部运行记录放入对应集合。同一台设备不能跨越两个集合。这样测试设备在训练阶段从未出现，与题目的部署目标一致。

（3）判断“加入正则化一定能改善未来新设备上的预测效果”是否成立，并简要说明理由。

参考解答 说法不成立。正则化通过限制系数大小等方式约束拟合，可能降低过拟合带来的误差，但也可能削弱模型对真实关系的拟合能力。若正则化过强，原本有用的系数也会被过度压缩，导致欠拟合，因此未来预测效果没有必然改善。

2 不带截距的 Ridge 回归

n, d 为正整数，X 为特征矩阵，y 为响应向量，w 为系数，维度及预测模型为

$$X \in \mathbb{R}^{n\times d}, \qquad y \in \mathbb{R}^n, \qquad w \in \mathbb{R}^d, \qquad \widehat{y} = Xw.$$

上标 $\top$ 表示转置，I_d 为单位矩阵，$\mathbb{1}_n$ 为长度为 n 的全 1 向量。对实向量 v，记

$$\|v\|_2^2 = v^\top v.$$

对固定的正则化参数 $\lambda > 0$，目标函数为

$$J_\lambda(w) = \frac{1}{2n}\|y - Xw\|_2^2 + \frac{\lambda}{2}\|w\|_2^2.$$

可直接使用：矩阵 $X^\top X + n\lambda I_d$ 可逆，目标函数的最小化解唯一。

（1）通过令梯度为零，推导最小化解 $\widehat{w}_\lambda$ 的显式表达式。保留梯度和线性方程两个中间步骤即可。

参考解答　将平方项展开，便于直接对系数求导：

$$\begin{aligned} J_\lambda(w) &= \frac{1}{2n}(y - Xw)^\top(y - Xw) + \frac{\lambda}{2}w^\top w \\ &= \frac{1}{2n}\left(y^\top y - 2w^\top X^\top y + w^\top X^\top X w\right) + \frac{\lambda}{2}w^\top w. \end{aligned}$$

其中常数项的梯度为零，线性项的梯度为其系数；由于 $X^\top X$ 对称，二次项的梯度为两倍矩阵乘向量。因此

$$\begin{aligned} \nabla J_\lambda(w) &= -\frac{1}{n}X^\top y + \frac{1}{n}X^\top X w + \lambda w \\ &= \frac{1}{n}X^\top(Xw - y) + \lambda w. \end{aligned}$$

令梯度为零，并将等式两边乘以 n，得到

$$\frac{1}{n}X^\top(Xw - y) + \lambda w = 0 \quad \Longleftrightarrow \quad (X^\top X + n\lambda I_d)w = X^\top y.$$

题干已给出可逆性和唯一性，故直接求得

$$\boxed{\widehat{w}_\lambda = (X^\top X + n\lambda I_d)^{-1}X^\top y.}$$

需要保留的比例因子是 $n\lambda$，其来源是残差项前的 $1/(2n)$。

（2）使用固定步长 $\eta > 0$ 的梯度迭代。记迭代次数为 t、系数误差为 e_t，已知

$$\begin{aligned} w_{t+1} &= w_t - \eta\nabla J_\lambda(w_t), \qquad t = 0, 1, 2, \ldots, \\ e_t &= w_t - \widehat{w}_\lambda, \qquad e_{t+1} = (I_d - \eta H)e_t, \\ H &= \frac{1}{n}X^\top X + \lambda I_d = Q\,\mathrm{diag}(\mu_1, \ldots, \mu_d)Q^\top, \\ Q^\top Q &= I_d, \qquad \mu_j > 0 \quad (j = 1, \ldots, d). \end{aligned}$$

其中 Q 为正交矩阵，μ_j 为特征值。从已给误差递推式出发，求使所有初值的误差都趋于零的步长范围。无需重新推导误差递推式。

参考解答 令特征值构成的对角矩阵和误差的新坐标分别为

$$D = \mathrm{diag}(\mu_1, \dots, \mu_d), \qquad u_t = Q^\top e_t.$$

由 $Q^\top Q = QQ^\top = I_d$ 和已给的误差递推，

$$\begin{aligned} u_{t+1} &= Q^\top (I_d - \eta Q D Q^\top) e_t \\ &= (I_d - \eta D) Q^\top e_t = (I_d - \eta D) u_t. \end{aligned}$$

各坐标因此独立地满足等比数列关系：

$$(u_{t+1})_j = (1 - \eta\mu_j)(u_t)_j, \qquad (u_t)_j = (1 - \eta\mu_j)^t (u_0)_j.$$

正交变换保持欧氏长度，故原误差趋于零等价于变换后的每个坐标趋于零：

$$\|e_t\|_2^2 = \|Qu_t\|_2^2 = \|u_t\|_2^2 = \sum_{j=1}^{d} (u_t)_j^2.$$

要对所有初值成立，每个等比因子都必须严格落在单位区间内。由正特征值假设，

$$|1 - \eta\mu_j| < 1 \quad \Longleftrightarrow \quad -1 < 1 - \eta\mu_j < 1 \quad \Longleftrightarrow \quad 0 < \eta < \frac{2}{\mu_j}.$$

所有方向同时满足，得到

$$\boxed{0 < \eta < \frac{2}{\max_{1 \le j \le d} \mu_j}.}$$

这一条件也具有必要性：若某个方向的等比因子绝对值不小于 1，选择初始误差仅在该特征向量方向上非零，即不能趋于零。下端点使迭代停留在初值，上端点使最大特征值方向的误差符号交替而大小不变。

（3） 令 $c \in \mathbb{R}$，保持特征矩阵不变，将响应改为

$$y' = y + c\mathbb{1}_n.$$

记新系数解为 $\widehat{w}'_\lambda$，推导系数变化量

$$\widehat{w}'_\lambda - \widehat{w}_\lambda.$$

参考解答 响应改变时特征矩阵和正则化参数均不变，故两次拟合使用同一个矩阵

$$A = X^\top X + n\lambda I_d.$$

分别代入新旧响应，并利用矩阵乘法的线性性展开：

$$\begin{aligned}\widehat{w}_\lambda &= A^{-1}X^\top y,\\ \widehat{w}'_\lambda &= A^{-1}X^\top(y + c\mathbb{1}_n)\\ &= A^{-1}X^\top y + cA^{-1}X^\top\mathbb{1}_n.\end{aligned}$$

相减后相同的响应项抵消，所求为

$$\boxed{\widehat{w}'_\lambda - \widehat{w}_\lambda = c(X^\top X + n\lambda I_d)^{-1}X^\top\mathbb{1}_n.}$$

右侧是长度为 d 的向量，与系数变化量的维度一致。

（4）设 j 为某一列的编号、$a \neq 0$ 为实数。将第 j 列乘以 a，同时将对应系数除以 a，其余列与系数不变。记变换后的矩阵和系数为 X', w'，即

$$X'_j = aX_j, \qquad w'_j = \frac{w_j}{a}.$$

用代数计算验证训练预测不变，并写出第 j 项正则化惩罚在变换前后的表达式。这里 X_j 表示第 j 列，w 是任意给定系数。

参考解答　除第 j 列以外均未改变，可将矩阵乘向量写成列向量的线性组合：

$$\begin{aligned}X'w' &= \sum_{k\neq j} X'_k w'_k + X'_j w'_j\\ &= \sum_{k\neq j} X_k w_k + (aX_j)\frac{w_j}{a}\\ &= \sum_{k\neq j} X_k w_k + X_j w_j = Xw.\end{aligned}$$

这证明训练预测保持不变。第 j 个系数对应的惩罚分别为

$$P_j = \frac{\lambda}{2}w_j^2, \qquad P'_j = \frac{\lambda}{2}(w'_j)^2 = \frac{\lambda}{2}\left(\frac{w_j}{a}\right)^2 = \frac{\lambda}{2a^2}w_j^2.$$

因此该惩罚乘上了 $1/a^2$，其他系数的惩罚不变。计算只使用 $a \neq 0$，正负变换均适用。这里验证的是题干指定的系数对应关系，并未断言重新拟合后的最优系数一定按此关系变化。

3　误差指标与误差估计

m 为评估样本数，y_i 和 $\widehat{y}_i$ 为第 i 个样本的真实值和预测值。定义

$$e_i = \widehat{y}_i - y_i, \qquad \bar{y} = \frac{1}{m}\sum_{i=1}^m y_i.$$

本题使用以下指标，其中决定系数的分母假定非零：

$$\mathrm{MSE} = \frac{1}{m}\sum_{i=1}^m e_i^2, \qquad \mathrm{MAE} = \frac{1}{m}\sum_{i=1}^m |e_i|,$$
$$R^2 = 1 - \frac{\sum_{i=1}^m e_i^2}{\sum_{i=1}^m (y_i - \bar{y})^2}.$$

（1）计算下列一个模型的三项指标：

$$m = 4, \qquad y = (1, 2, 3, 4)^\top, \qquad \widehat{y} = (1, 2, 3, 8)^\top.$$

参考解答 由题设的残差方向，逐点相减得到

$$e = \widehat{y} - y = (0, 0, 0, 4)^\top.$$

残差平方和及绝对残差和分别为

$$\sum_{i=1}^{4} e_i^2 = 0 + 0 + 0 + 16 = 16, \qquad \sum_{i=1}^{4} |e_i| = 0 + 0 + 0 + 4 = 4.$$

真实值均值为

$$\bar{y} = \frac{1 + 2 + 3 + 4}{4} = 2.5.$$

决定系数分母为

$$\begin{aligned} \sum_{i=1}^{4} (y_i - \bar{y})^2 &= (-1.5)^2 + (-0.5)^2 + (0.5)^2 + (1.5)^2 \\ &= 2.25 + 0.25 + 0.25 + 2.25 = 5. \end{aligned}$$

代入三个定义即可得到

$$\boxed{\text{MSE} = 4, \qquad \text{MAE} = 1, \qquad R^2 = 1 - \frac{16}{5} = -2.2.}$$

本例决定系数为负是正常的计算结果，不应改成零。

（2）两个互不重叠的评估子集分别有 m_1, m_2 个样本，一个模型在这两个子集上的均方误差分别为 M_1, M_2，数值为

$$m_1 = 90, \qquad m_2 = 10, \qquad M_1 = 1, \qquad M_2 = 9.$$

从两个子集的残差平方和出发，计算合并全部样本后的均方误差。

参考解答 记第 k 个子集的残差平方和为 S_k。根据均方误差的定义，

$$M_k = \frac{S_k}{m_k} \quad \Longrightarrow \quad S_k = m_k M_k.$$

两集合不重叠，合并时残差平方和相加，样本数也相加。因此合并均方误差为

$$M_{\text{all}} = \frac{S_1 + S_2}{m_1 + m_2} = \frac{m_1 M_1 + m_2 M_2}{m_1 + m_2}.$$

带入已给数值，

$$S_1 = 90 \cdot 1 = 90, \qquad S_2 = 10 \cdot 9 = 90, \qquad \boxed{M_{\text{all}} = \frac{90 + 90}{90 + 10} = 1.8.}$$

不同子集的误差应按样本数加权，不能忽略子集大小。

（3）设 K 为正整数，$\widehat{R}_j$ 为第 j 个候选模型的随机误差估计，$\mathbb{E}$ 表示期望。假设

$$\mathbb{E}[|\widehat{R}_j|] < \infty, \qquad R_j = \mathbb{E}[\widehat{R}_j], \qquad j = 1, \ldots, K.$$

证明不等式：

$$\mathbb{E}\left[\min_{1\le j\le K} \widehat{R}_j\right] \le \min_{1\le j\le K} R_j.$$

参考解答 对每次随机取值和任意固定的候选编号 j，最小值均不超过该候选的误差估计：

$$\min_{1\le k\le K} \widehat{R}_k \le \widehat{R}_j.$$

期望保持这一大小关系，因此

$$\mathbb{E}\left[\min_{k} \widehat{R}_k\right] \le \mathbb{E}[\widehat{R}_j] = R_j \qquad (j = 1, \ldots, K).$$

由于候选个数有限，常数中有一个最小者，记其编号为 j_*，则

$$R_{j_*} = \min_{1\le j\le K} R_j.$$

在前面的不等式中选取这个固定编号，得到

$$\boxed{\mathbb{E}\left[\min_{k} \widehat{R}_k\right] \le R_{j_*} = \min_{j} R_j.}$$

这里选取的是期望最小的固定编号，并没有把随机最小值与期望交换次序。各误差估计不需要相互独立。若需核对期望存在性，有限性和题设给出

$$\left|\min_{k} \widehat{R}_k\right| \le \sum_{k=1}^{K} |\widehat{R}_k|, \qquad \mathbb{E}\left[\sum_{k=1}^{K} |\widehat{R}_k|\right] < \infty.$$

4 Ridge 与 Lasso 的解

n, d 为正整数，X 为特征矩阵，y 为响应向量，w 为系数。维度及模型为

$$X \in \mathbb{R}^{n\times d}, \qquad y \in \mathbb{R}^n, \qquad w \in \mathbb{R}^d, \qquad \widehat{y} = Xw.$$

X_j 表示第 j 列，I_d 为单位矩阵，上标 $\top$ 表示转置。对实向量 v，记

$$\|v\|_2^2 = \sum_j v_j^2, \qquad \|v\|_1 = \sum_j |v_j|.$$

固定参数 $\lambda > 0$，定义

$$J_R(w) = \frac{1}{2n}\|y - Xw\|_2^2 + \frac{\lambda}{2}\|w\|_2^2,$$
$$J_L(w) = \frac{1}{2n}\|y - Xw\|_2^2 + \lambda\|w\|_1.$$

（1）假设列向量满足以下条件，并定义向量 z：

$$\frac{1}{n}X^\top X = I_d, \qquad z = \frac{1}{n}X^\top y.$$

推导 Lasso 最小化解的各分量。需分正、负、零三种情况，在零点使用左右导数，写出包含边界的分段式。

参考解答 先展开残差平方，使用列向量条件和向量 z 的定义，得到

$$\begin{aligned} J_L(w) &= \frac{1}{2n}y^\top y - \frac{1}{n}w^\top X^\top y + \frac{1}{2n}w^\top X^\top Xw + \lambda\sum_{j=1}^{d}|w_j| \\ &= C + \frac{1}{2}w^\top w - w^\top z + \lambda\sum_{j=1}^{d}|w_j| \\ &= C + \sum_{j=1}^{d}\left(\frac{1}{2}w_j^2 - z_j w_j + \lambda|w_j|\right), \qquad C = \frac{1}{2n}y^\top y. \end{aligned}$$

常数 C 与系数无关，求和中各项分别只依赖一个分量，所以逐个最小化以下一元函数即可：

$$f_j(u) = \frac{1}{2}u^2 - z_j u + \lambda|u|.$$

正半轴上绝对值等于系数本身，负半轴上等于其相反数。因此

$$f_j'(u) = \begin{cases} u - z_j + \lambda, & u > 0, \\ u - z_j - \lambda, & u < 0. \end{cases}$$

正半轴驻点及其可行条件为

$$u = z_j - \lambda > 0 \quad \Longleftrightarrow \quad z_j > \lambda.$$

负半轴驻点及其可行条件为

$$u = z_j + \lambda < 0 \quad \Longleftrightarrow \quad z_j < -\lambda.$$

零点不使用普通导数，而检查左导数不大于零、右导数不小于零：

$$\begin{aligned} f'_{j,-}(0) &= -z_j - \lambda \le 0, \\ f'_{j,+}(0) &= -z_j + \lambda \ge 0. \end{aligned} \quad \Longleftrightarrow \quad -\lambda \le z_j \le \lambda.$$

两侧导数都随系数严格递增，且跨越零点时向上跳跃，因此上述位置是唯一的全局最小点。这包括恰好位于阈值上的情形。合并为

$$\boxed{\widehat{w}_{L,j} = \begin{cases} z_j - \lambda, & z_j > \lambda, \\ 0, & |z_j| \le \lambda, \\ z_j + \lambda, & z_j < -\lambda. \end{cases}}$$

（2）在相同的列向量条件下，利用以下已给公式计算指定参数对应的 Ridge 系数向量，可以使用公式：

$$\widehat{w}_R = \frac{z}{1+\lambda},$$
$$d = 3, \qquad z = (2, -0.6, 0.1)^\top, \qquad \lambda = 0.5.$$

参考解答 正则化参数加上 1 后为 1.5，由已给公式，各分量分别除以这个数：

$$\widehat{w}_{R,1} = \frac{2}{1.5} = \frac{4}{3},$$
$$\widehat{w}_{R,2} = \frac{-0.6}{1.5} = -\frac{2}{5},$$
$$\widehat{w}_{R,3} = \frac{0.1}{1.5} = \frac{1}{15}.$$

所以

$$\boxed{\widehat{w}_R = \left(\frac{4}{3}, -\frac{2}{5}, \frac{1}{15}\right)^\top.}$$

（3）本小问改设两列完全相同，向量 x 和标量 c 满足

$$d = 2, \qquad X_1 = X_2 = x \in \mathbb{R}^n,$$
$$\frac{1}{n}\|x\|_2^2 = 1, \qquad c = \frac{1}{n}x^\top y > \lambda > 0.$$

求 Lasso 的全部最小化解并给出推导。可令系数和 $s = w_1 + w_2$，利用

$$|w_1| + |w_2| \ge |s|$$

及等号条件，将问题化为关于系数和的一元问题。

参考解答 两列相同，预测只取决于两个系数之和。令

$$s = w_1 + w_2, \qquad Xw = xw_1 + xw_2 = xs.$$

利用题设的归一化条件和标量 c，残差项展开为

$$\frac{1}{2n}\|y - xs\|_2^2 = \frac{1}{2n}y^\top y - \frac{s}{n}x^\top y + \frac{s^2}{2n}x^\top x$$
$$= C - cs + \frac{1}{2}s^2, \qquad C = \frac{1}{2n}y^\top y.$$

由三角不等式，目标函数有下界

$$J_L(w) = C + \frac{1}{2}s^2 - cs + \lambda(|w_1| + |w_2|) \geq C + g(s),$$

其中定义

$$g(s) = \frac{1}{2}s^2 - cs + \lambda|s|.$$

这个下界对任意指定的系数和都可达到，例如取系数为 $(s, 0)$。所以先求下界的最优系数和，再求达到下界的所有分配方式。

在负半轴上，导数为

$$g'(s) = s - c - \lambda < 0 \qquad (s < 0).$$

零点的两个单侧导数为

$$g'_-(0) = -c - \lambda < 0, \qquad g'_+(0) = -c + \lambda < 0.$$

因此零点及负半轴均不是最小点。正半轴上的导数和唯一零点为

$$g'(s) = s - c + \lambda, \qquad s_* = c - \lambda > 0.$$

导数在这个位置由负变正，所以最优系数和唯一。接下来检查三角不等式的等号条件：对两个实数，同号或至少一个为零时取等号；若两者异号且都非零，则严格大于系数和的绝对值。结合最优系数和为正，等号条件正好是

$$w_1 \geq 0, \qquad w_2 \geq 0, \qquad w_1 + w_2 = c - \lambda.$$

用实数 t 表示第一个系数，就得到全部解

$$\boxed{(\widehat{w}_{L,1}, \widehat{w}_{L,2}) = (t, c - \lambda - t), \qquad 0 \leq t \leq c - \lambda.}$$

为核对没有遗漏：任何系数的目标值都不小于最优下界，而上述系数确实达到该下界。因此其他最小化解也必须同时具有最优系数和并使三角不等式取等号，这恰好就是已列出的解集。只给出两个系数相等的一个解，不能覆盖全部解。

（4）固定其他系数后，第 j 个系数的一元目标如下。其中 $a_j > 0$、ρ_j 为给定实数，u 表示待更新的系数：

$$q_j(u) = \frac{a_j}{2}u^2 - \rho_j u + \lambda|u|, \qquad u \in \mathbb{R}.$$

写出使该目标最小的系数更新值。可直接利用第（1）小问的分段求导结果，无需重新展开原目标或重复完整证明。

参考解答 因 $a_j > 0$，将目标除以该正数不改变最小化位置：

$$\frac{q_j(u)}{a_j} = \frac{1}{2}u^2 - \frac{\rho_j}{a_j}u + \frac{\lambda}{a_j}|u|.$$

这与第（1）小问的一元形式相同，只需将线性项系数替换为 ρ_j/a_j，惩罚参数替换为 λ/a_j。例如正分支条件为

$$\frac{\rho_j}{a_j} > \frac{\lambda}{a_j} \quad \Longleftrightarrow \quad \rho_j > \lambda,$$

此时最优值为

$$u = \frac{\rho_j}{a_j} - \frac{\lambda}{a_j} = \frac{\rho_j - \lambda}{a_j}.$$

同理得到另两支，合并为

$$\boxed{w_j^{\text{new}} = \begin{cases} (\rho_j - \lambda)/a_j, & \rho_j > \lambda, \\ 0, & |\rho_j| \le \lambda, \\ (\rho_j + \lambda)/a_j, & \rho_j < -\lambda. \end{cases}}$$

写成原始线性系数的条件时，阈值仍为 λ，分母作用于整个差或和。

5 一维 Ridge 的误差

n 为正整数，输入 $x_1, \dots, x_n$ 为固定实数，$\beta \in \mathbb{R}$ 为固定真实系数。响应模型为

$$s = \frac{1}{n}\sum_{i=1}^{n} x_i^2 > 0, \qquad y_i = \beta x_i + \varepsilon_i \quad (i = 1, \dots, n).$$

训练噪声相互独立。$\mathbb{E}$ 和 Var 分别表示期望与方差，并假设

$$\mathbb{E}[\varepsilon_i] = 0, \qquad \mathrm{Var}(\varepsilon_i) = \sigma^2 > 0.$$

对参数 $\lambda \ge 0$，Ridge 系数估计量及其偏差、方差和均方误差记为

$$\begin{aligned} \widehat{\beta}_\lambda &= \frac{s\beta + n^{-1}\sum_{i=1}^{n} x_i\varepsilon_i}{s + \lambda}, \\ B_\lambda &= \mathbb{E}[\widehat{\beta}_\lambda] - \beta, \qquad V_\lambda = \mathrm{Var}(\widehat{\beta}_\lambda), \\ M_\lambda &= \mathbb{E}[(\widehat{\beta}_\lambda - \beta)^2]. \end{aligned}$$

以上估计量表达式可直接使用。

（1）推导偏差 B_λ 和方差 V_λ。

参考解答　将训练噪声的加权平均记为随机变量 T：

$$T = \frac{1}{n}\sum_{i=1}^{n} x_i\varepsilon_i, \qquad \widehat{\beta}_\lambda = \frac{s\beta + T}{s + \lambda}.$$

输入、真实系数及参数都是固定量；由期望的线性性和噪声零均值，

$$\mathbb{E}[T] = \frac{1}{n}\sum_{i=1}^{n} x_i \mathbb{E}[\varepsilon_i] = 0, \qquad \mathbb{E}[\widehat{\beta}_\lambda] = \frac{s\beta}{s+\lambda}.$$

按偏差定义减去真实系数，

$$B_\lambda = \frac{s\beta}{s+\lambda} - \beta = \frac{s\beta - (s+\lambda)\beta}{s+\lambda} = \boxed{-\frac{\lambda\beta}{s+\lambda}}.$$

独立噪声的交叉协方差为零。由加权和的方差公式，

$$\begin{aligned}\operatorname{Var}(T) &= \frac{1}{n^2}\sum_{i=1}^{n} x_i^2 \operatorname{Var}(\varepsilon_i) \\ &= \frac{\sigma^2}{n^2}\sum_{i=1}^{n} x_i^2 = \frac{\sigma^2}{n^2}\, ns = \frac{s\sigma^2}{n}.\end{aligned}$$

固定平移不改变方差，乘以固定系数后方差乘以其平方，所以

$$V_\lambda = \operatorname{Var}\left(\frac{s\beta + T}{s+\lambda}\right) = \frac{\operatorname{Var}(T)}{(s+\lambda)^2} = \boxed{\frac{s\sigma^2}{n(s+\lambda)^2}}.$$

整个推导直接使用题设估计量，没有重新求解回归问题。

（2）已知下列均方误差公式：

$$M_\lambda = \frac{\lambda^2\beta^2 + s\sigma^2/n}{(s+\lambda)^2}.$$

取下列参数，通过求导求使均方误差最小的 $\lambda \geq 0$：

$$s = 1, \qquad n = 20, \qquad \sigma^2 = 4, \qquad \beta = 1.$$

只需求最优参数，不要求其他参数取值的误差表或零真实系数情形。

参考解答 将四个给定参数代入已给误差公式，注意噪声方差与样本数的比值为 $4/20 = 1/5$：

$$M_\lambda = \frac{\lambda^2 + 1/5}{(1+\lambda)^2}, \qquad \lambda \geq 0.$$

使用商的求导法则，

$$\begin{aligned}\frac{\mathrm{d}M_\lambda}{\mathrm{d}\lambda} &= \frac{2\lambda(1+\lambda)^2 - 2(1+\lambda)(\lambda^2+1/5)}{(1+\lambda)^4} \\ &= \frac{2\lambda(1+\lambda) - 2(\lambda^2+1/5)}{(1+\lambda)^3} \\ &= \frac{2(\lambda - 1/5)}{(1+\lambda)^3}.\end{aligned}$$

在题设的非负参数范围内，分母严格为正。因此误差在最优点之前严格递减，在其后严格递增：

$$\frac{\mathrm{d}M_\lambda}{\mathrm{d}\lambda} \begin{cases} < 0, & 0 \leq \lambda < 1/5, \\ = 0, & \lambda = 1/5, \\ > 0, & \lambda > 1/5. \end{cases}$$

由此得到整个可行范围上的唯一最小值位置

$$\boxed{\lambda_* = \frac{1}{5} = 0.2.}$$

只令导数为零得到的是候选点；导数符号变化说明它确实是全局最优参数。

（3）固定新输入 $x_0 \in \mathbb{R}$，新响应为

$$Y_0 = \beta x_0 + \varepsilon_0.$$

其中 ε_0 独立于全部训练噪声，均值为 0、方差为 σ^2。只用 M_λ、x_0 和 σ^2 表示下列预测误差期望，并给出推导：

$$\mathbb{E}[(Y_0 - x_0\widehat{\beta}_\lambda)^2].$$

期望同时对训练噪声和新样本噪声计算，无需代入数值。

参考解答 将新响应代入预测误差，得到

$$Y_0 - x_0\widehat{\beta}_\lambda = \beta x_0 + \varepsilon_0 - x_0\widehat{\beta}_\lambda = \varepsilon_0 - x_0(\widehat{\beta}_\lambda - \beta).$$

先完整展开平方，再取期望：

$$\begin{aligned}\mathbb{E}[(Y_0 - x_0\widehat{\beta}_\lambda)^2] = \mathbb{E}[\varepsilon_0^2] - 2x_0\mathbb{E}[\varepsilon_0(\widehat{\beta}_\lambda - \beta)] \\ + x_0^2\mathbb{E}[(\widehat{\beta}_\lambda - \beta)^2].\end{aligned}$$

新噪声为零均值，所以第一项为

$$\mathbb{E}[\varepsilon_0^2] = \mathrm{Var}(\varepsilon_0) + (\mathbb{E}[\varepsilon_0])^2 = \sigma^2.$$

估计量仅由训练噪声和固定输入决定。新噪声与全部训练噪声独立，因此也与估计量独立，交叉项可以分解为期望之积：

$$\mathbb{E}[\varepsilon_0(\widehat{\beta}_\lambda - \beta)] = \mathbb{E}[\varepsilon_0]\,\mathbb{E}[\widehat{\beta}_\lambda - \beta] = 0.$$

这一步不要求估计量无偏。最后一项中的期望恰好是题目定义的系数均方误差，故

$$\boxed{\mathbb{E}[(Y_0 - x_0\widehat{\beta}_\lambda)^2] = \sigma^2 + x_0^2 M_\lambda.}$$

结果已按指定的三个量表达，不再展开均方误差或代入数值。