

习题课 1: 向量与矩阵的微分

1 从标量微分出发

若实函数在标量点 t 可微, 对趋近零的增量 h , 有

$$f(t+h) - f(t) = f'(t)h + r(h), \quad \frac{|r(h)|}{|h|} \rightarrow 0.$$

微分 $df = f'(t)dt$ 表示其中关于增量的线性部分。符号 dt 表示供这个线性映射作用的输入增量。

例如 $f(t) = t^2$ 时, 真实变化与微分分别为

$$\Delta f = (t+h)^2 - t^2 = 2th + h^2, \quad df = 2t dt.$$

在 $t = 3$ 、 $h = 0.01$ 时, 真实变化为 0.0601, 一阶近似为 0.06。两者差别是二阶项。

2 标量对向量: 微分与梯度

2.1 梯度是微分的系数向量

设 $x \in \mathbb{R}^p$, 标量函数 $f: \mathbb{R}^p \rightarrow \mathbb{R}$ 在 x 可微。定义列向量梯度

$$\nabla_x f(x) = \left[\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_p} \right]^\top \in \mathbb{R}^p.$$

对任意小增量 $h \in \mathbb{R}^p$, 有

$$f(x+h) - f(x) = \nabla_x f(x)^\top h + o(\|h\|_2), \quad df = \nabla_x f(x)^\top dx.$$

这里 $o(\|h\|_2)$ 表示余项除以 $\|h\|_2$ 后趋于零。微分是把向量增量映射到标量变化的线性映射; 梯度是该映射在欧氏内积下的列向量表示。两者不是同一个概念。

例如, 设 $x = (x_1, x_2)^\top$, 取

$$f(x) = x_1^2 + 3x_1x_2, \quad df = (2x_1 + 3x_2)dx_1 + 3x_1dx_2, \quad \nabla_x f = \begin{bmatrix} 2x_1 + 3x_2 \\ 3x_1 \end{bmatrix}.$$

在 $x = (1, 2)^\top$ 、 $h = (0.01, -0.02)^\top$ 时, 线性近似与真实变化为

$$\nabla_x f(x)^\top h = 0.02, \quad f(x+h) - f(x) = 0.0195.$$

2.2 方向导数与负梯度方向

固定方向 $v \in \mathbb{R}^p$, 对可微函数沿直线求一元导数:

$$D_v f(x) = \left. \frac{d}{dt} f(x + tv) \right|_{t=0} = \nabla_x f(x)^\top v.$$

当限制 $\|v\|_2 = 1$ 且梯度非零时, 由 Cauchy-Schwarz 不等式,

$$\nabla_x f(x)^\top v \geq -\|\nabla_x f(x)\|_2, \quad v = -\frac{\nabla_x f(x)}{\|\nabla_x f(x)\|_2}$$

使一阶变化最小。这解释了梯度下降的方向选择; 步长过大时, 高阶变化不能忽略, 不能仅由方向正确推断每一步一定下降。此处的“最陡”依赖欧氏长度约束。

维度核查

对标量 f 与列向量 $x \in \mathbb{R}^p$, 梯度必须是 $p \times 1$, 微分必须是标量:

$$\underbrace{df}_{1 \times 1} = \underbrace{(\nabla_x f)^\top}_{1 \times p} \underbrace{dx}_{p \times 1}.$$

梯度为零只说明所有一阶方向变化为零, 不足以判断极小值。例如 $f(t) = -t^2$ 在零点的导数也为零。

3 用微分推导线性函数与二次型

3.1 乘积法则保留矩阵乘法顺序

对形状可相乘的、依赖同一变量的矩阵函数 U, V , 逐元素使用乘积法则可得

$$d(UV) = (dU)V + UdV, \quad d(U^\top) = (dU)^\top.$$

如果 A 是与求导变量无关的常矩阵, 则 $dA = 0$ 。不要因使用了乘积法则而交换矩阵顺序。

3.2 线性函数与内积

令 $a \in \mathbb{R}^p$ 为常向量、 $x \in \mathbb{R}^p$ 为变量。则

$$f(x) = a^\top x, \quad df = a^\top dx, \quad \boxed{\nabla_x f = a}.$$

若 $u, v \in \mathbb{R}^p$ 都依赖求导变量, 则

$$d(u^\top v) = (du)^\top v + u^\top dv.$$

取 $u = v = x$, 利用标量等于自身转置, 得到

$$d(x^\top x) = (dx)^\top x + x^\top dx = 2x^\top dx, \quad \boxed{\nabla_x \frac{1}{2} \|x\|_2^2 = x}.$$

3.3 一般二次型

设 $A \in \mathbb{R}^{p \times p}$ 为任意常矩阵, $f(x) = x^\top Ax$ 。两个 x 都会变化:

$$\begin{aligned} df &= (dx)^\top Ax + x^\top Adx \\ &= x^\top A^\top dx + x^\top Adx \\ &= ((A + A^\top)x)^\top dx. \end{aligned}$$

因此

$$\boxed{\nabla_x (x^\top Ax) = (A + A^\top)x}.$$

只有当 $A = A^\top$ 时, 才可写成 $2Ax$ 。验证一个非对称例子:

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}, \quad x^\top Ax = x_1^2 + 2x_1x_2 + 3x_2^2, \quad \nabla_x f = \begin{bmatrix} 2x_1 + 2x_2 \\ 2x_1 + 6x_2 \end{bmatrix}.$$

二次型只依赖矩阵的对称部分, 因为反对称部分满足

$$x^\top (A - A^\top)x = 0, \quad x^\top Ax = x^\top \frac{A + A^\top}{2} x.$$

4 向量对向量: Jacobian 与链式法则

4.1 Jacobian 的行列约定

设 $g: \mathbb{R}^p \rightarrow \mathbb{R}^m$ 可微, 输出为列向量 $z = g(x)$ 。此处采用输出分量作行、输入分量作列的 Jacobian:

$$J_g(x) = \left[\frac{\partial g_i}{\partial x_j} \right]_{m \times p}, \quad \boxed{dz = J_g(x)dx}.$$

例如, 若 $z = Ax + b$, 其中 $A \in \mathbb{R}^{m \times p}$ 、 $b \in \mathbb{R}^m$ 为常量, 则

$$J_g = A, \quad dz = Adx.$$

这与标量函数的列梯度约定相容: 标量输出时, Jacobian 是一行, 恰好等于梯度的转置。不同教材可能采用不同排列约定, 不能脱离定义比较转置符号。

4.2 标量复合函数

令 $F(x) = \phi(g(x))$, 其中 $\phi: \mathbb{R}^m \rightarrow \mathbb{R}$ 可微。先对中间变量 z 写微分, 再代入其变化:

$$\begin{aligned} dF &= \nabla_z \phi(z)^\top dz \\ &= \nabla_z \phi(z)^\top J_g(x) dx \\ &= (J_g(x)^\top \nabla_z \phi(z))^\top dx. \end{aligned}$$

所以

$$\boxed{\nabla_x F(x) = J_g(x)^\top \nabla_z \phi(g(x))}.$$

形状为 $(p \times m)(m \times 1) = p \times 1$ 。转置来自把输入增量的系数改写成列梯度, 并不是为了凑维度随意添加的。

4.3 例: 带线性映射的平方误差

给定常量 $A \in \mathbb{R}^{m \times p}$ 、 $b \in \mathbb{R}^m$, 变量为 $x \in \mathbb{R}^p$ 。设

$$r = Ax - b, \quad F(x) = \frac{1}{2} \|r\|_2^2, \quad dr = Adx.$$

则

$$dF = r^\top dr = r^\top Adx, \quad \boxed{\nabla_x F = A^\top (Ax - b)}.$$

先算输出残差, 再用 $A^\top$ 映射回参数空间。残差是 m 维, 参数梯度是 p 维, 通常不能直接把残差作为梯度。

练习: 定义 $g(x_1, x_2) = (x_1 x_2, x_1 + x_2)^\top$, $\phi(z) = \frac{1}{2} \|z\|_2^2$ 。先写出 Jacobian, 再在 $x = (1, 2)^\top$ 处求 $\nabla_x(\phi \circ g)$ 。

5 应用：无截距线性回归与 Ridge

设设计矩阵 $X \in \mathbb{R}^{n \times p}$ 、标签 $y \in \mathbb{R}^n$ 为常量，参数 $w \in \mathbb{R}^p$ 为变量。本节使用无截距模型 $\hat{y} = Xw$ 。定义

$$J_\lambda(w) = \frac{1}{2n} \|Xw - y\|_2^2 + \frac{\lambda}{2} \|w\|_2^2, \quad \lambda \geq 0.$$

5.1 先设残差，再读梯度

设 $r = Xw - y$ ，则 $dr = Xdw$ 。逐项求微分：

$$\begin{aligned} dJ_\lambda &= \frac{1}{n} r^\top dr + \lambda w^\top dw \\ &= \left[\frac{1}{n} X^\top (Xw - y) + \lambda w \right]^\top dw. \end{aligned}$$

因此

$$\nabla_w J_\lambda = \frac{1}{n} X^\top (Xw - y) + \lambda w.$$

平方项求导产生的因子 2 与目标前的 1/2 抵消；1/n 不能消失。若目标的缩放约定改变，梯度与正则化参数的含义也应一起核对。

5.2 梯度的变化与最优解

继续对梯度求微分。因为本例中 X, y, λ 都固定，

$$d(\nabla_w J_\lambda) = \underbrace{\left(\frac{1}{n} X^\top X + \lambda I_p \right)}_H dw.$$

矩阵 $H \in \mathbb{R}^{p \times p}$ 就是本目标的 Hessian；其一般定义与几何含义将在第 6 节介绍。本例的 H 不随 w 改变。对任意 $v \in \mathbb{R}^p$ ，

$$v^\top H v = \frac{1}{n} \|Xv\|_2^2 + \lambda \|v\|_2^2 \geq 0.$$

令梯度为零得到驻点方程

$$(X^\top X + n\lambda I_p)w = X^\top y.$$

若 w_* 满足驻点方程，直接展开平方项可得，对任意增量 $h \in \mathbb{R}^p$ ，

$$J_\lambda(w_* + h) - J_\lambda(w_*) = \frac{1}{2} h^\top H h \geq 0.$$

因此驻点是全局最优解。当 $\lambda > 0$ 时， H 正定，非零增量对应严格增加，故最优解唯一；当 $\lambda = 0$ 时， X 列满秩才保证 H 正定，不能无条件写逆矩阵。列不满秩时最优参数不唯一，但最优拟合向量仍唯一。

5.3 Hessian 决定稳定步长

设 w_* 是一个最优解， $e^{(t)} = w^{(t)} - w_*$ 。对本节二次目标的固定步长更新，

$$e^{(t+1)} = (I_p - \eta H) e^{(t)}.$$

在特征值为 $\mu > 0$ 的方向上，误差每步乘以 $1 - \eta\mu$ 。若最大特征值 $L > 0$ ，则 $0 < \eta < 2/L$ 保证所有正曲率方向收缩；零特征值方向不会收缩。该结论利用了本目标的 Hessian 恒定，不能仅凭一般非线性函数在某一点的 Hessian 就保证整个训练过程稳定。

6 Hessian 与 Laplace 算子

6.1 Hessian: 梯度的 Jacobian

设标量函数 $f: \mathbb{R}^p \rightarrow \mathbb{R}$ 在所讨论点的邻域内具有连续二阶偏导。梯度 $\nabla_x f \in \mathbb{R}^p$ 是一个向量函数，对它求 Jacobian 得到 Hessian:

$$H_f(x) = J_{\nabla f}(x) = \left[\frac{\partial}{\partial x_j} \left(\frac{\partial f}{\partial x_i} \right) \right]_{p \times p}, \quad \boxed{d(\nabla_x f) = H_f(x) dx}.$$

连续二阶偏导保证混合偏导可以交换，因此 $H_f(x) = H_f(x)^\top$ 。对角元描述同一坐标方向的二阶变化，非对角元描述一个坐标改变时，另一个坐标对应的偏导如何变化。

沿用第 2 节的函数 $f(x) = x_1^2 + 3x_1x_2$ ，有

$$\nabla_x f = \begin{bmatrix} 2x_1 + 3x_2 \\ 3x_1 \end{bmatrix}, \quad H_f = \begin{bmatrix} 2 & 3 \\ 3 & 0 \end{bmatrix}.$$

这里 $\partial f / \partial x_2 = 3x_1$ 不依赖 x_2 ，但它依赖 x_1 ；所以右下角为零，不意味着第二行都为零。

6.2 二阶近似与方向曲率

一阶近似只记录梯度，二阶 Taylor 展开还保留 Hessian 给出的二次项：

$$f(x+h) = f(x) + \nabla_x f(x)^\top h + \frac{1}{2} h^\top H_f(x) h + o(\|h\|_2^2).$$

其中余项除以 $\|h\|_2^2$ 后趋于零。若 f 是二次函数，则该展开精确成立，没有余项；第 5 节的 Ridge 目标就是这种情况。

固定方向 $v \in \mathbb{R}^p$ ，沿直线 $x + tv$ 两次使用链式法则，得到

$$\frac{d}{dt} f(x + tv) = \nabla_x f(x + tv)^\top v, \quad \left. \frac{d^2}{dt^2} f(x + tv) \right|_{t=0} = v^\top H_f(x) v.$$

对单位方向 v ，这个二次型给出沿该方向的二阶变化；若 v 是单位特征向量，它等于对应的特征值。

6.3 驻点处能判断什么

设 x_* 满足 $\nabla_x f(x_*) = 0$ 。若 $H_f(x_*)$ 正定，即对所有非零 v 都有 $v^\top H_f(x_*) v > 0$ ，则 x_* 是严格局部极小点；负定时为严格局部极大点；同时存在正、负特征值时为鞍点。

半正定本身不足以判定局部极小。例如一元函数 t^4 、 $-t^4$ 、 t^3 在零点的一阶、二阶导数都为零，却分别具有局部极小、局部极大与非极值的情形。对一般函数，驻点附近的结论是局部的；第 5 节之所以能判定全局最优，是因为其精确二次展开对任意增量都成立。

6.4 Laplace: 各坐标二阶偏导之和

在欧氏空间的直角坐标下, Laplace 算子 (拉普拉斯算子) 作用于标量函数 f , 定义为

$$\Delta_x f = \sum_{i=1}^p \frac{\partial^2 f}{\partial x_i^2} = \text{tr}(H_f(x)).$$

这里 $\text{tr}(M)$ 表示方阵 M 的对角线元素之和, 称为迹; 下一节将继续使用它。 $H_f(x)$ 是 $p \times p$ 矩阵, 而 $\Delta_x f$ 是标量。算子 Δ_x 与第 1 节表示有限变化的 $\Delta f = f(t+h) - f(t)$ 含义不同, 本节用下标 x 标明求导变量。

若把向量场 $u = (u_1, \dots, u_p)^\top$ 的散度定义为

$$\text{div } u = \sum_{i=1}^p \frac{\partial u_i}{\partial x_i},$$

则 Laplace 也可写为 $\Delta_x f = \text{div}(\nabla_x f)$ 。对称 Hessian 的迹等于其特征值之和, 因此 Laplace 汇总各方向的曲率信息, 却不能保留每个方向的符号和大小。

6.5 例: Laplace 为正, 不代表局部极小

设 $x = (x_1, x_2)^\top$, 比较

$$f(x) = x_1^2 + x_2^2, \quad g(x) = 2x_1^2 - x_2^2.$$

二者分别满足

$$H_f = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, \quad \Delta_x f = 4; \quad H_g = \begin{bmatrix} 4 & 0 \\ 0 & -2 \end{bmatrix}, \quad \Delta_x g = 2.$$

原点处两者梯度均为零、Laplace 均为正, 但 f 在原点取严格极小值, g 在原点为鞍点: 沿第一坐标轴增加, 沿第二坐标轴减小。同样, $q(x) = x_1^2 - x_2^2$ 满足 $\Delta_x q = 0$, 却不是常函数或线性函数。不能仅由 Laplace 的符号判断驻点类型。

6.6 回到第 5 节的 Ridge 目标

对 $w \in \mathbb{R}^p$ 求导, 其 Hessian 与 Laplace 分别为

$$H_{J_\lambda} = \frac{1}{n} X^\top X + \lambda I_p, \quad \Delta_w J_\lambda = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^p X_{ij}^2 + p\lambda.$$

正则化项使 Hessian 的每个特征值增加 λ , 使其迹增加 $p\lambda$ 。在第 5 节的步长分析中, 控制最大允许步长的是最大特征值, 而非仅仅特征值之和。两个正定矩阵可以迹相同但最大特征值不同, 例如 $\text{diag}(1, 3)$ 与 $\text{diag}(2, 2)$, 因此相同 Laplace 不意味着相同的稳定步长范围。

7 标量对矩阵：迹与 Frobenius 内积

7.1 定义与工具

对方阵 $M \in \mathbb{R}^{q \times q}$ ，迹是对角线元素之和：

$$\text{tr}(M) = \sum_{i=1}^q M_{ii}.$$

对同形矩阵 $U = (U_{ij})_{p \times q}, V = (V_{ij})_{p \times q}$ ，Frobenius 内积和范数定义为

$$\langle U, V \rangle_F = \sum_{i,j} U_{ij} V_{ij} = \text{tr}(U^\top V), \quad \|U\|_F^2 = \sum_{i,j} U_{ij}^2.$$

因此，矩阵参数 $W \in \mathbb{R}^{p \times q}$ 的标量函数 $f(W)$ ，梯度与 W 同形：

$$(\nabla_W f)_{ij} = \frac{\partial f}{\partial W_{ij}}, \quad \boxed{\text{d}f = \text{tr}((\nabla_W f)^\top \text{d}W)}.$$

这就是将所有元素的偏导与对应增量配对求和。

7.2 迹的轮换性质

若 $A \in \mathbb{R}^{m \times p}$ 、 $B \in \mathbb{R}^{p \times m}$ ，展开元素可得

$$\text{tr}(AB) = \sum_{i=1}^m \sum_{j=1}^p A_{ij} B_{ji} = \text{tr}(BA).$$

在乘积有定义且结果为方阵时，可以循环移动多个因子，例如

$$\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB).$$

一般不能写 $\text{tr}(ABC) = \text{tr}(ACB)$ 。另外，标量等于自身转置，故 $\text{tr}(M) = \text{tr}(M^\top)$ 。

7.3 例：多输出回归的矩阵梯度

给定 $X \in \mathbb{R}^{n \times p}$ 、 $Y \in \mathbb{R}^{n \times q}$ ，变量 $W \in \mathbb{R}^{p \times q}$ ，定义

$$F(W) = \frac{1}{2n} \|XW - Y\|_F^2 + \frac{\lambda}{2} \|W\|_F^2.$$

令 $R = XW - Y$ ，则 $\text{d}R = X \text{d}W$ 。由内积的乘积法则，

$$\begin{aligned} \text{d}F &= \frac{1}{n} \text{tr}(R^\top \text{d}R) + \lambda \text{tr}(W^\top \text{d}W) \\ &= \text{tr} \left[\left(\frac{1}{n} X^\top R + \lambda W \right)^\top \text{d}W \right]. \end{aligned}$$

所以

$$\boxed{\nabla_W F = \frac{1}{n} X^\top (XW - Y) + \lambda W} \in \mathbb{R}^{p \times q}.$$

检查特殊情况 $q = 1$ ，应退化为第 5 节向量参数的梯度。

8 参考习题

要求。每题均先写变量和常量的形状，再写微分，最后给出梯度或 Jacobian。

练习 1: 两个依赖同一变量的因子

设常向量 $a, b \in \mathbb{R}^p$ ，变量 $x \in \mathbb{R}^p$ ，定义

$$f(x) = (a^\top x)(b^\top x).$$

求 df 与 $\nabla_x f$ 。当 $a = b$ 时，核对是否与平方函数求导一致。

练习 2: 有耦合项的平方误差

给定

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad J(w) = \frac{1}{4} \|Xw - y\|_2^2 + \frac{1}{2} \|w\|_2^2.$$

变量为 $w \in \mathbb{R}^2$ 。求 $\nabla_w J(w)$ 、Hessian 与 $\Delta_w J$ ；从 $w^{(0)} = 0$ 出发、取步长 $\eta = 1/2$ ，求一次更新后的 $w^{(1)}$ 。说明这个步长是否使所有误差方向收缩。

练习 3: 逐分量非线性与链式法则

给定常矩阵 $A \in \mathbb{R}^{m \times p}$ 、常向量 $b, y \in \mathbb{R}^m$ ，变量为 $x \in \mathbb{R}^p$ 。定义 $z = Ax + b$ ，向量 s 的第 i 个分量为 $s_i = z_i^2$ ，并令

$$F(x) = \frac{1}{2} \|s - y\|_2^2.$$

用链式法则求 $\nabla_x F$ 。

练习 4: 带权平方误差

给定常量 $X \in \mathbb{R}^{n \times p}$ 、 $y \in \mathbb{R}^n$ 与对称矩阵 $C \in \mathbb{R}^{n \times n}$ ，变量为 $w \in \mathbb{R}^p$ 。设

$$F(w) = \frac{1}{2} (Xw - y)^\top C (Xw - y).$$

求梯度。若不再假设 C 对称，答案如何修改？求梯度本身是否需要 C 正定？若 C 半正定，对目标非负性能作出什么判断？

练习 5: 左右同时有线性映射

给定常量 $A \in \mathbb{R}^{m \times p}$ 、 $B \in \mathbb{R}^{q \times r}$ 、 $C \in \mathbb{R}^{m \times r}$ ，变量为 $W \in \mathbb{R}^{p \times q}$ 。求

$$F(W) = \frac{1}{2} \|AWB - C\|_F^2$$

对 W 的梯度。要求推导中写明迹的循环移动发生在哪一步，并检查梯度形状。

9 方法总结

1. 标明求导变量与固定变量；写出所有形状。
2. 引入残差或中间变量，用乘积法则、链式法则求微分。
3. 向量变量整理为 $g^\top dx$ ，矩阵变量整理为 $\text{tr}(G^\top dW)$ ，再写出梯度。
4. 用维度、标量特例和数值差分交叉核验。

参考解答：练习与参考习题

链式法则随堂练习。对第 4 节给定的函数，

$$J_g(x) = \begin{bmatrix} x_2 & x_1 \\ 1 & 1 \end{bmatrix}, \quad g(1, 2) = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \quad \nabla_x(\phi \circ g) = J_g(x)^\top g(x).$$

代入得到 $\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} (2, 3)^\top = (7, 5)^\top$ 。

练习 1

两项因子都依赖 x ，故

$$\begin{aligned} df &= (b^\top x)a^\top dx + (a^\top x)b^\top dx, \\ \nabla_x f &= (b^\top x)a + (a^\top x)b \in \mathbb{R}^p. \end{aligned}$$

当 $a = b$ 时，梯度为 $2(a^\top x)a$ 。它与先对标量 $a^\top x$ 平方求导、再用链式法则的结果一致。

练习 2

本题样本数为 2，正则化参数为 1。直接代入或逐项微分，得到

$$\nabla_w J = \frac{1}{2} X^\top (Xw - y) + w = \begin{bmatrix} 2w_1 + \frac{1}{2}w_2 - \frac{3}{2} \\ \frac{1}{2}w_1 + \frac{3}{2}w_2 - 1 \end{bmatrix}, \quad H = \begin{bmatrix} 2 & \frac{1}{2} \\ \frac{1}{2} & 3 \end{bmatrix}.$$

Laplace 为

$$\Delta_w J = \text{tr}(H) = 2 + \frac{3}{2} = \frac{7}{2}.$$

因此

$$\nabla_w J(0) = \begin{bmatrix} -3/2 \\ -1 \end{bmatrix}, \quad w^{(1)} = 0 - \frac{1}{2} \nabla_w J(0) = \begin{bmatrix} 3/4 \\ 1/2 \end{bmatrix}.$$

Hessian 的两个特征值为 $(7 + \sqrt{5})/4$ 和 $(7 - \sqrt{5})/4$ ，均为正。最大特征值约为 2.309，所以 $\eta = 1/2 < 2/2.309$ ，两个方向均收缩。也可检查

$$J(0) = \frac{5}{4}, \quad J(w^{(1)}) = \frac{9}{16} < \frac{5}{4}.$$

练习 3

因为 $s_i = z_i^2$, 逐分量微分得到

$$ds = 2 \operatorname{diag}(z) dz, \quad dz = A dx, \quad dF = (s - y)^\top ds.$$

其中 $\operatorname{diag}(z)$ 表示对角线上依次为 $z_1, \dots, z_m$ 、其他元素为零的方阵, 于是

$$dF = 2(s - y)^\top \operatorname{diag}(z) A dx, \quad \boxed{\nabla_x F = 2A^\top \operatorname{diag}(z)(s - y)} \in \mathbb{R}^p.$$

若用逐元素乘法符号 $\odot$, 也可写为 $2A^\top(z \odot (s - y))$ 。这里的平方和乘法都是逐分量操作。

练习 4

令 $r = Xw - y \in \mathbb{R}^n$, $dr = Xdw$ 。对称矩阵 C 下,

$$\begin{aligned} dF &= \frac{1}{2}((dr)^\top Cr + r^\top C dr) \\ &= r^\top C dr = r^\top C X dw, \end{aligned}$$

所以 $\nabla_w F = X^\top C(Xw - y)$ 。若 C 非对称, 则应保留两项:

$$\boxed{\nabla_w F = X^\top \frac{C + C^\top}{2}(Xw - y)}.$$

求导不需要正定性。若 C 对称半正定, 按定义 $r^\top Cr \geq 0$, 故目标非负; 正定性是关于目标性质的条件, 不是乘积法则成立的条件。

练习 5

设 $R = AWB - C \in \mathbb{R}^{m \times r}$ 。因为 A, B, C 均固定,

$$dR = AdWB, \quad dF = \operatorname{tr}(R^\top AdWB).$$

把最右侧因子 B 循环移到最左侧, 得到

$$dF = \operatorname{tr}(BR^\top AdW) = \operatorname{tr}((A^\top RB^\top)^\top dW).$$

故

$$\boxed{\nabla_W F = A^\top (AWB - C) B^\top}.$$

形状检查为 $(p \times m)(m \times r)(r \times q) = p \times q$, 与 W 相同。若取 $B = I_q$, 退化为多输出最小二乘; 若进一步只有单列输出, 则退化为向量梯度。

常用结果：记住条件，不只记住右侧

下表中 a, A, X, y 均为常量， x, w 为列向量， W 为矩阵变量；各乘积形状均需相容。

标量函数	相应变量的梯度
$a^\top x$	a
$\frac{1}{2} x^\top x$	x
$x^\top Ax$	$(A + A^\top)x$
$\frac{1}{2} \ Ax - b\ _2^2$	$A^\top(Ax - b)$
$\frac{1}{2n} \ Xw - y\ _2^2 + \frac{\lambda}{2} \ w\ _2^2$	$X^\top(Xw - y)/n + \lambda w$
$\text{tr}(A^\top W)$, A 与 W 同形	A
$\frac{1}{2} \ AWB - C\ _F^2$	$A^\top(AWB - C)B^\top$