


人工智能与机器学习基础


Lecture 03: 性能评估

冯文杰

人工智能与数据科学学院
中国科学技术大学




案例分析



要用直线拟合数据还是别的?

这可不是线性关系啊!


案例分析



是否可能是一个二次函数?

看起来不错，
有没有更好的!

案例分析




可能需要用高阶多项式函数?

我可以最小化你的残差平方和 (MSE)!

案例分析

你相信这种拟合结果吗？



MSE虽然最小化了,
但预测效果很差

我的房子
不可能这么
便宜!

模型永远是对现实的近似

“Remember that all models are wrong; the practical question is how wrong do they have to be to not be useful.”


“要记住，所有的模型都是错的；
真正的问题在于，它们得错到什么程度才会变得毫无用处。”

— George Box, 1987.

Recap 概念：假设类

- **模型**：我们对世界运行方式的假设
- **假设**： x 与 y 之间的预期关系
- **回归模型**：

- $y = f(x) + \epsilon$, $\mathbb{E}(\epsilon) = 0$
- y ：真实值
- $\hat{y} = f(x)$ ：预测值
- ϵ ：误差 $\epsilon = y - \hat{y}$




- **假设类**：所有候选模型的集合（即从输入 x 到输出 y 的映射函数 f ）
 - 注意：此时模型尚未涉及任何“线性”假设。

Recap 概念：假设类


- **学习过程**：从假设类 H 中选择**最优假设** h^* ，使其在训练数据上的风险（Risk）最小化
- **三种风险 Risks**
 - 经验风险（*Empirical Risk*）
 - 模型在当前训练数据集上的平均预测误差（或损失）。
 - 期望风险（*Expected Risk*）
 - 模型在所有可能的、未见过的数据样本上的期望预测误差。
 - 结构风险（*Structural Risk*）
 - 通过限制模型复杂度来防止过拟合。

模型分析与提升




评估损失：训练误差 --- 数据集

- 假设这些点为全部样本集合




评估损失：训练误差 --- 训练集

- 假设这些点为全部样本集合
- **训练集**：用于让模型学习的**已知输入与对应输出**的样本集合（蓝点）




评估损失：训练误差

- $\text{Training_error}(\hat{\mathbf{w}}) = \frac{1}{N} \sum_{i=1}^N (y_i - f_{\hat{\mathbf{w}}}(x_i))^2$




评估损失：训练误差



- $\text{Training_error}(\hat{\mathbf{w}}) = \frac{1}{N} [(\$_{train1} - f_{\hat{\mathbf{w}}}(\text{sq. ft.}_{train1}))^2 + (\$_{train2} - f_{\hat{\mathbf{w}}}(\text{sq. ft.}_{train2}))^2 + \dots \text{all training houses}]$





训练误差 vs 模型复杂度





训练误差 vs 模型复杂度





训练误差 vs 模型复杂度



训练误差 vs 模型复杂度




训练误差 vs 模型复杂度




训练误差 vs 模型复杂度

- 增加模型复杂度可以降低训练误差




训练误差 vs 模型复杂度

- 训练误差是衡量预测性能的好指标吗？
- 训练误差往往过于乐观，因为 $\hat{w}$ 是在训练数据上拟合得到的




单纯小的训练误差 $\neq$ 好的预测性能
(除非训练数据已经涵盖了你
未来可能遇到的所有情况)

模型分析与提升



泛化误差

- 我们更希望估计在**所有可能的 (🏠, \$)** 样本对上的**总体误差**而不仅仅是**在训练集上的训练误差**



泛化误差

- 我们更希望估计在**所有可能的 (🏠, \$)** 样本对上的**总体误差**而不仅仅是训练集上的训练误差

对所有可能的 (x, y) 对进行加权平均,
权重取决于每个对出现的概率

泛化误差

$$\text{Generalization Error} = \mathbb{E}_{x,y}[\mathcal{L}(y, f^{\hat{w}}(x))]$$

$\hat{w}$ 在训练数据上拟合得到的

泛化误差定义

- Generalization Error

$$= \sum_{\forall (x_i, y_i) \in \mathcal{D}} L(y_i, f_{\hat{w}}(x_i)) p(x, y)$$

$$= \sum_{\forall (x_i, y_i) \in \mathcal{D}} L(y_i, f_{\hat{w}}(x_i)) p(x) p(y|x)$$


(x, y) 的可能性由联合分布 $p(x, y)$
给出 $p(x, y) = p(x)p(y|x)$

$$= \int_{(x, y) \in \mathcal{D}} L(y_i, f_{\hat{w}}(x_i)) p(x, y) dx dy$$


$$= \int_{(x, y) \in \mathcal{D}} L(y_i, f_{\hat{w}}(x_i)) p(x) p(y|x) dx dy$$

$$\text{Generalization Error} = \mathbb{E}_{x, y} [L(y_i, f_{\hat{w}}(x_i))]$$


泛化误差 vs 模型复杂度





泛化误差 vs 模型复杂度





假设已知 $p(x, y)$ 分布





泛化误差 vs 模型复杂度





泛化误差 vs 模型复杂度



泛化误差 vs 模型复杂度




泛化误差 vs 模型复杂度




泛化误差 vs 模型复杂度

- **不可行**: 缺少对整体样本及其分布 $p(x,y)$ 的可访问性




代替方案：测试集

- **不可行**：缺少对整体样本及其分布 $p(x,y)$ 的可访问性
- **代替方法**：通过未包含在训练集中的数据近似估计泛化误差



- 将现有数据分为训练集（蓝）与测试集（灰）
- 测试集就成为了“你可能看到的一切”的代理
- **永远不要在测试集上训练！**

模型分析与提升



测试误差定义

- 测试误差 = 测试集上的平均损失

- Test Error = $\frac{1}{|\mathcal{D}_{\text{Test}}|} \sum_{\forall (x_i, y_i) \in \mathcal{D}_{\text{Test}}} L(y_i, f_{\hat{w}}(x_i))$

approximate


$\hat{w}$ 在训练数据上拟合得到的

$$\text{Generalization Error} = \int_{(x,y) \in \mathcal{D}} L(y_i, f_{\hat{w}}(x_i)) p(x, y) dx dy$$


训练 -> 测试

- 将数据分割，保留“测试”数据
 - 实际中，训练集/测试集的比例：70%/30%，80%/20%
- 仅用训练集训练数据（估计参数）
- 通过计算测试数据上的测试损失测试“性能”


训练/泛化/测试误差 vs. 模型复杂度




训练/泛化/测试误差 vs. 模型复杂度



训练/泛化/测试误差 vs. 模型复杂度




训练/泛化/测试误差 vs. 模型复杂度




过拟合 (Overfitting)


- 使用 $\hat{\omega}$
- 如果存在一个模型，其估计的参数 ω' 满足：
 - Training Error($\hat{\omega}$) < Training Error(ω');
 - Generalization Error($\hat{\omega}$) > Generalization Error(ω')



训练误差和乐观度



模型分析与提升




误差的来源

- 预测建模过程中，误差通常来自三个方面
 - **Noise**，不可避免的数据噪声
 - **Bias**，模型本身的系统性偏差
 - **Variance**，模型在不同数据采样下的方差波动



数据固有存在噪声

- 噪声是**不可避免的**，即便模型能够完全拟合真实函数 f ，由于观测数据中固有的不确定性，预测结果仍会有误差




偏差贡献

- Bias (偏差) 反映了模型预测的系统性误差，即模型表达能力不足导致的与真实函数 $f(x)$ 的偏离
- 如果我们用一个常数函数来拟合复杂的数据关系




偏差贡献

- 若考虑所有可能的大小为 N 的训练数据集，期望的模型应该是 $f_{\bar{w}}$




偏差贡献

- **偏差**: $\text{Bias}(x) = f_{w_{true}}(x) - f_{\bar{w}}(x)$
 - 需要检验我们的方法是否具有足够的表达能力来逼近真实函数 $f(x)$ 。
 - 若模型灵活性不足，预测中将不可避免地产生系统性误差。




方差贡献

- 方差衡量：在不同的训练集采样下，模型的预测 $f(x)$ 与其期望预测 $\mathbb{E}[f(x)]$ 之间的波动程度。





方差贡献

- 方差衡量：在不同的训练集采样下，模型的预测 $f(x)$ 与其期望预测 $\mathbb{E}[f(x)]$ 之间的波动程度。




方差贡献

- 设想使用高阶多项式来进行拟合




方差贡献

- 在不同训练集上得到的具体拟合曲线差异很大 $\rightarrow$ 方差很高 $\rightarrow$ 泛化性能差




方差贡献

High complexity $\rightarrow$ High variance




高复杂度模型的偏差



High complexity $\rightarrow$ Low bias

Low complexity $\rightarrow$ High bias



偏差和方差

- 泛化误差

- 形式化: $\mathbb{E}[(y - \hat{f}(x))^2]$

观测值 预测值

$$= \left(\mathbb{E}[\hat{f}(x)] - f(x) \right)^2 + \mathbb{E} \left[(\hat{f}(x) - \mathbb{E}[\hat{f}(x)])^2 \right] + \sigma^2$$

$$= \underbrace{Var(x)}_{\text{不可约误差}} + \underbrace{bias^2(x)}_{\text{偏差的平方}} + \underbrace{variance(x)}_{\text{方差}}$$

不可约误差
真实值与观测值
之间的方差

偏差的平方
真实值与模型预测
值期望之间的方差


方差
模型预测值与预测
值期望之间的方差

$$\sigma^2 = \mathbb{E}_y \left[\left(y - \underbrace{f(x)}_{\mathbb{E}_{y|x}[y]} \right)^2 \right]$$

- 偏差 (**bias**): 模型依靠自身能力进行预测的平均准确程度 (准)
- 方差 (**variance**): 模型在不同训练集上表现出来的差异程度 (确)

偏差-方差权衡

- 偏差-方差均衡



偏差-方差权衡

- 偏差-方差均衡

$$\text{Err}(x) = \text{Bias}^2 + \text{Variance} + \text{Irreducible Error}$$


- 示例

- Voting Intentions:

- Sample # = 50 from the phone book

Voting Republican	Voting Democratic	Non-Respondent	Total
13	16	21	50


- Republican: $13/(13 + 16) = 44.8\%$?
 - They actually *lose* by 10 points



偏差-方差权衡

- 偏差与方差的管理
 - 以方差为代价尽可能减少偏差
 - 机理：即使方差较大，至少在平均情况下预测是好的 **×**
 - **原因**：实际中往往只有一次数据集的采样结果；更重要的是在确定的数据上的性能
 - **结论**：偏差、方差同样重要，不能偏废
 - Bagging和重采样以减少方差
 - Bootstrap Averaging, Random Forests

任何模型的最佳平衡点是：
当偏差的增加等于方差的减少时，
模型的复杂度就会达到平衡。



$$\frac{dBias}{dComplexity} = -\frac{dVariance}{dComplexity}$$


示例

- 动画展示的示例

- <https://mlu-explain.github.io/bias-variance/>

为什么有三种来源

- **Average squared error** at x_t
$$= \sigma^2 + [bias(f_{\hat{w}}(\mathbf{x}))]^2 + var(f_{\hat{w}}(\mathbf{x}))$$



为什么有三种来源

- 期望预测误差

$$= \mathbb{E}_{train} [\text{generalization error of } \hat{w}_{train}]$$

$$= \mathbb{E}_{train} \left[\mathbb{E}_{x,y} \left[L \left(y, f_{\hat{w}_{train}}(x) \right) \right] \right]$$

- 特定 x : $L \left(y, f_{\hat{w}_{train}}(x) \right) = \left(y - f_{\hat{w}_{train}}(x) \right)^2$

- 期望预测误差: $\mathbb{E}_{train} \left[E_{y|x} \left[\left(y - f_{\hat{w}_{train}}(x) \right)^2 \right] \right]$

为什么有三种来源

Expected prediction error at $\mathbf{x}$

$$\begin{aligned} &= E_{\text{train}} [E_{y|\mathbf{x}} [(y - \underbrace{f_{\hat{\mathbf{w}}(\text{train})}(\mathbf{x})}_a)^2]] \\ &= E_{\text{train}} [E_{y|\mathbf{x}} [((y - \underbrace{f_{\text{true}}(\mathbf{x})}_b) + (\underbrace{f_{\text{true}}(\mathbf{x}) - f_{\hat{\mathbf{w}}(\text{train})}(\mathbf{x})}_b))^2]] \\ &= \cancel{E_{\text{train}} [E_{y|\mathbf{x}} [(y - f)^2]]} + 2 E_{\text{train}} [E_{y|\mathbf{x}} [\underbrace{(y - f)}_e (\underbrace{f - \hat{f}}_e)]] \\ &\quad + E_{\text{train}} [\cancel{E_{y|\mathbf{x}} [(f - \hat{f})^2]]] \\ &\quad \quad \quad \triangleq \text{MSE}(\hat{f}) \text{ mean square error} \\ &= \sigma^2 + \text{MSE}(\hat{f}) \end{aligned}$$

Handwritten notes in orange:
- $\underbrace{(y - f)}_e = \sigma^2$ by defn
- $\underbrace{E[\hat{f}]}_e = 0$
- $E[\hat{f} - \hat{f}] = 0$

Shorthand:
 $f_{\text{true}} \rightarrow \hat{f}$
 $f_{\hat{\mathbf{w}}(\text{train})} \rightarrow \hat{f}$

$$\begin{aligned} E[(a+b)^2] &= E[a^2] + 2E[ab] + E[b^2] \\ E[ab] &= E[a]E[b] \text{ if } a, b \text{ uncorr (or, ind.)} \end{aligned}$$

为什么有三种来源

MSE(x)


$$\begin{aligned} &= E_{\text{train}}[(\overbrace{f_{\text{true}}(\mathbf{x})}^f - \overbrace{f_{\hat{\mathbf{w}}(\text{train})}(\mathbf{x})}^f)^2] \\ &= E_{\text{train}}[(\overbrace{f_{\text{true}}(\mathbf{x})}^f - \overbrace{f_{\bar{\mathbf{w}}}(\mathbf{x})}^f) + (\overbrace{f_{\bar{\mathbf{w}}}(\mathbf{x})}^f - \overbrace{f_{\hat{\mathbf{w}}(\text{train})}(\mathbf{x})}^f)]^2] \\ &= \underbrace{E_{\text{train}}[(f - \bar{f})^2]}_{\substack{\uparrow \\ E_{\text{train}}[\hat{f}]}} + \underbrace{2 E_{\text{train}}[(f - \bar{f})(\bar{f} - \hat{f})]}_{\substack{\text{not fun} \\ \text{of "train"}}} + \underbrace{E_{\text{train}}[(\bar{f} - \hat{f})^2]}_{\text{Var}(\hat{f})} \\ &\quad \underbrace{= \text{bias}^2(\hat{f}) \text{ by defn}} \quad \underbrace{2(f - \bar{f}) E_{\text{train}}[\bar{f} - \hat{f}]}_{\substack{= \bar{f} - E[\hat{f}] \\ = 0 \text{ by defn}}} \\ &= \text{bias}^2(\hat{f}) + \text{var}(\hat{f}) \end{aligned}$$

Handwritten notes:
- $\bar{f}$ is the mean of f .
- $\hat{f}$ is a random variable.
- $\bar{f}$ is not a function of the training data.

为什么有三种来源

- Expected prediction error at $\mathbf{x}$


$$\begin{aligned} & \mathbb{E}_{train} \left[E_{y|x} \left[\left(y - f_{\hat{\mathbf{w}}_{train}}(x) \right)^2 \right] \right] \\ &= \sigma^2 + \text{MSE}(f_{\hat{\mathbf{w}}}(\mathbf{x})) \\ &= \sigma^2 + [\text{bias}(f_{\hat{\mathbf{w}}}(\mathbf{x}))]^2 + \text{var}(f_{\hat{\mathbf{w}}}(\mathbf{x})) \end{aligned}$$



3 sources of error


误差 vs (训练) 数据量的关系

- 固定的模型复杂度




误差 vs (训练) 数据量的关系

- 固定的模型复杂度




误差 vs (训练) 数据量的关系

- 固定的模型复杂度




误差 vs (训练) 数据量的关系

- 固定的模型复杂度



误差 vs 训练数据量的关系

- 如果我们增加模型复杂度会发生什么?
 - 噪声?
 - 方差?
 - 偏差?




高方差和高偏差检测

- **Regime 1**

- High Variance
- Symptoms
 - Training error $\ll$ Test error
 - Training error $< \epsilon$
 - Test error $> \epsilon$

- Remedies


- Add more training data
- Reduce model complexity
 - Complex models are prone to high variance
- Bagging



高方差和高偏差检测


- **Regime 2**

- High Bias
- Symptoms
 - Training error $> \epsilon$
- Remedies
 - Add features
 - Use more complex model
 - kernelize, use non-linear models
 - Boosting




神经网络中的偏差-方差

- U-型测试误差曲线与矛盾观察



偏差-方差的普遍直觉




神经网络中 偏差-方差的矛盾观察

Brady Neal, On the Bias-Variance Tradeoff: Textbooks Need an Update, A Modern Perspective, ArXiv, 2019



神经网络中的偏差-方差

- 简单和复杂假设下的偏差和方差



简单和复杂假设下的偏差和方差

随着假设类大小的增加,
偏差在减少




随着网络宽度的增加
偏差和方差都会减小

Brady Neal, On the Bias-Variance Tradeoff: Textbooks Need an Update, A Modern Perspective, ArXiv, 2019

现代的偏差-方差均衡

- 双下降曲线猜想：The Double Descent Curve



Belkin, M., Hsu, D., Ma, S., & Mandal, S. (2019). Reconciling modern machine learning practice and the classical bias-variance trade-off. *Proceedings of the National Academy of Sciences*.

Questions

