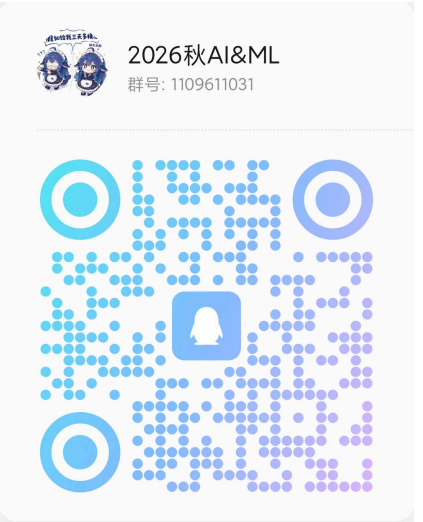
人工智能与机器学习基础

Lecture 08: 聚类

冯文杰

人工智能与数据科学学院

中国科学技术大学



提纲

- 聚类方法的动机
- 聚类算法
- 聚类质量评估与簇数选择
- K-means的局限性与失效模式
- 混合模型：基于模型的聚类

提纲

- **聚类方法的动机**
- 聚类算法
- 聚类质量评估与簇数选择
- K-means的局限性与失效模式
- 混合模型：基于模型的聚类

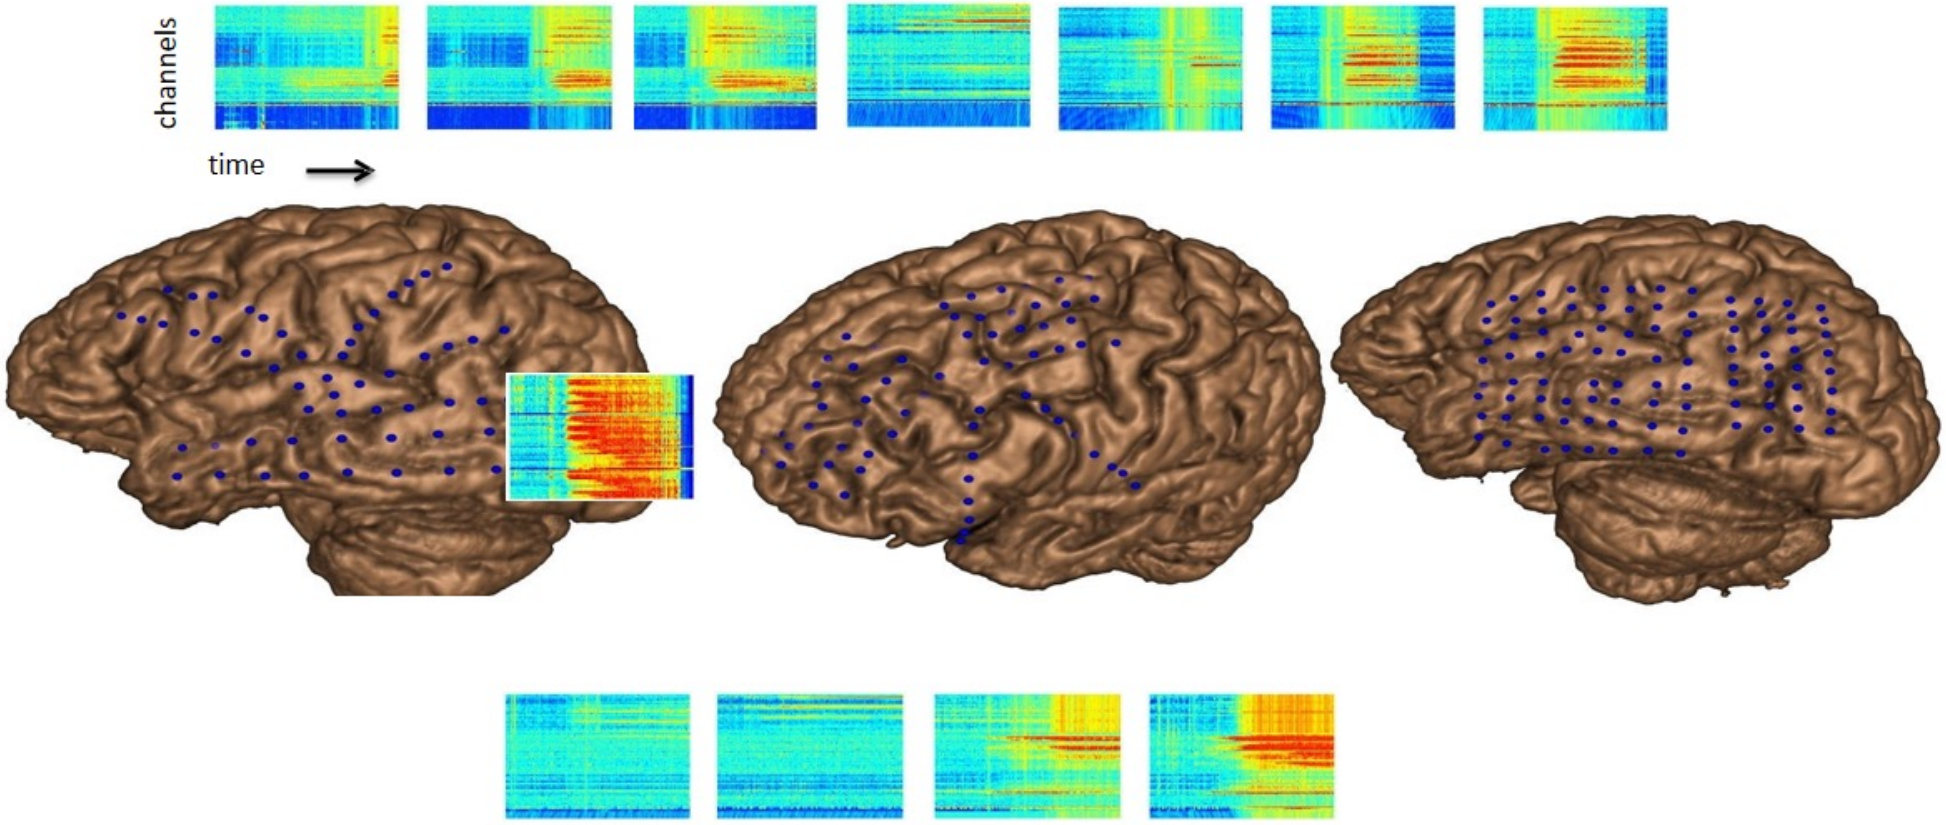
图像聚类

- 发现相似图像的分组
  - 海洋
  - 粉色花朵
  - 狗
  - 日落
  - 云朵



病人及癫痫类型特征化

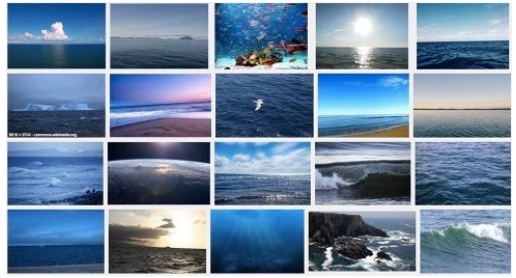
- 通过聚类方法识别具有相似特征的病人群体，或区分不同类型的癫痫发作模式



提纲

- **聚类方法的动机**
  - 聚类：一种无监督学习任务
- 聚类算法
- 聚类质量评估与簇数选择
- K-means的局限性与失效模式
- 混合模型：基于模型的聚类

如果训练数据的标签已知会怎样?



海洋



狗



落日



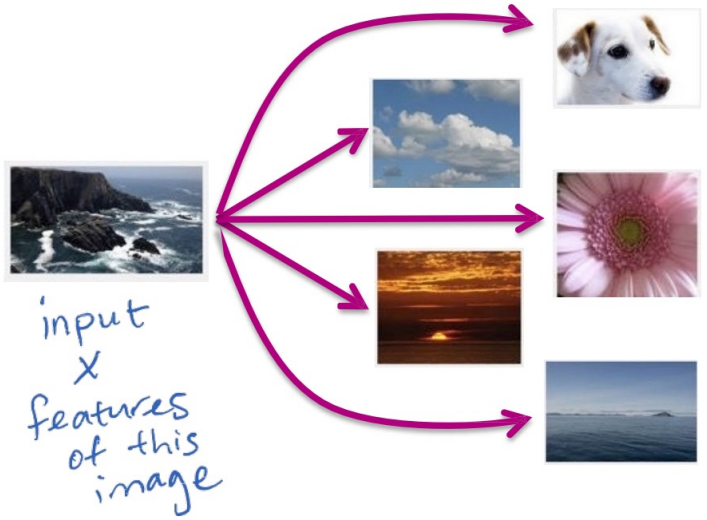
粉色花朵



云

多分类问题：学习类别判别边界回顾

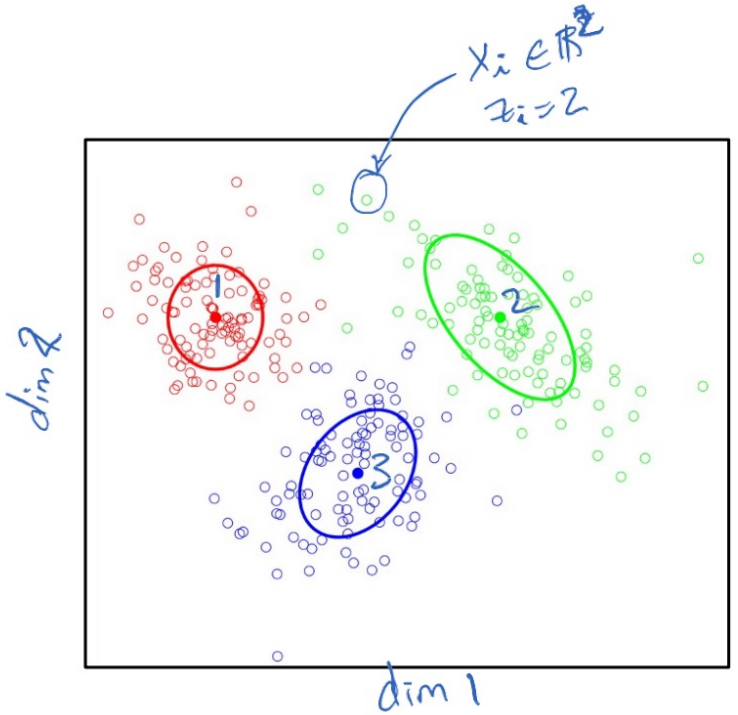
- 如果我们拥有训练数据的标签y（存在于训练集中；人工标注）
  - 我们就不再需要“发现”簇；
  - 而是学习一个映射函数 $f(x) \rightarrow y$ ，使得模型能对新样本预测正确的类别。



有监督学习的样例

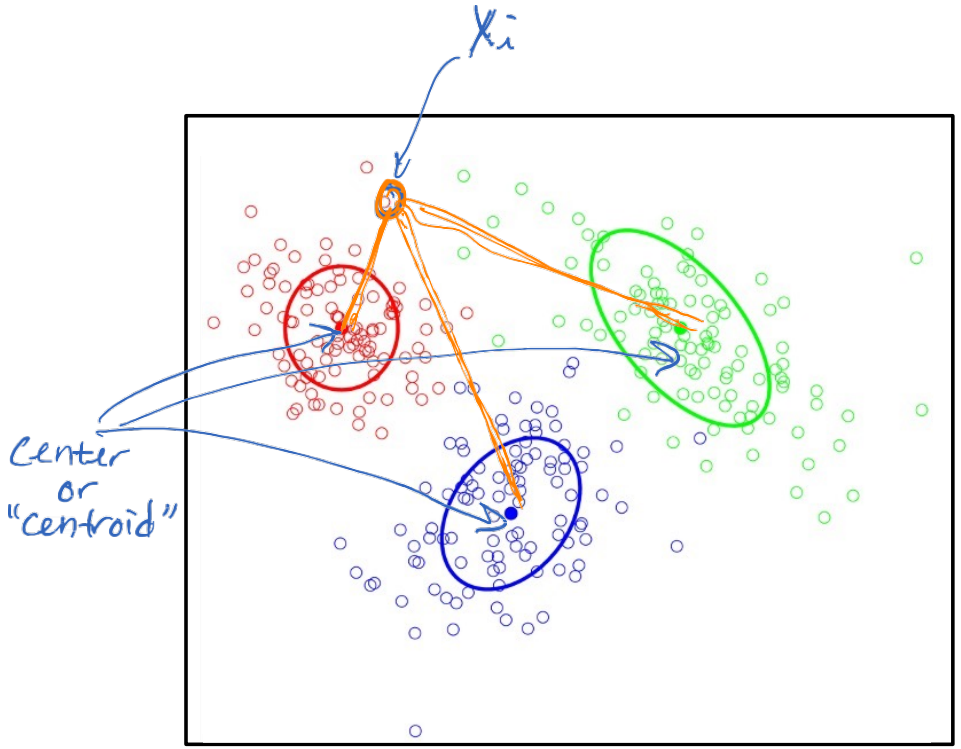
聚类问题：发现数据中自然分组

- 当没有提供标签时，模型需要仅依据输入特征来发现数据的内在结构或模式
  - 输入：图像特征x_i
  - 输出：聚类标签 z_i （不存在于训练集；由算法自动分配，而非人工标注）



如何定义一个簇?

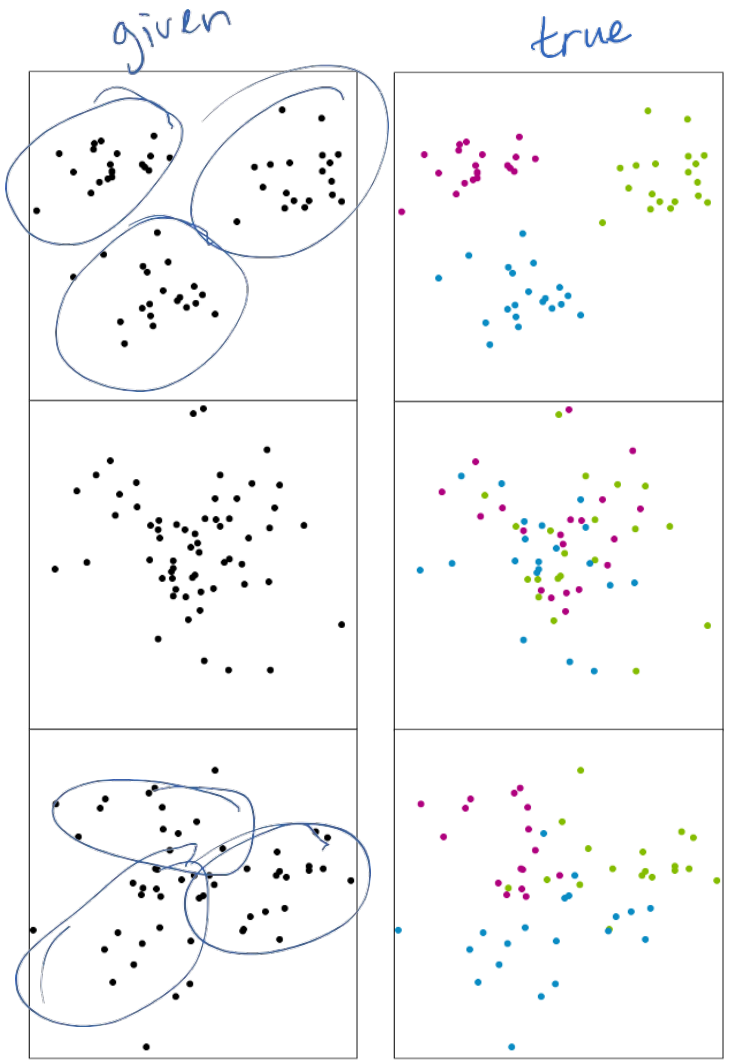
- 每个簇通常由以下因素决定
  - 中心（center） — 簇的“代表点”或“均值”；
  - 形状/分布（shape or spread）— 簇内样本的空间分布或方差;
  - 但实际应用中，我们常用距离中心的远近来近似定义簇归属。



当观测样本x_i在该簇下的得分最高时（得分可简化为样本与簇中心的距离，距离越近，分数越高），将其分配到簇 k

对无监督学习的期待

Easy（容易）



数据结构清晰、簇之间分离明显时，聚类算法能够轻松发现潜在分组。

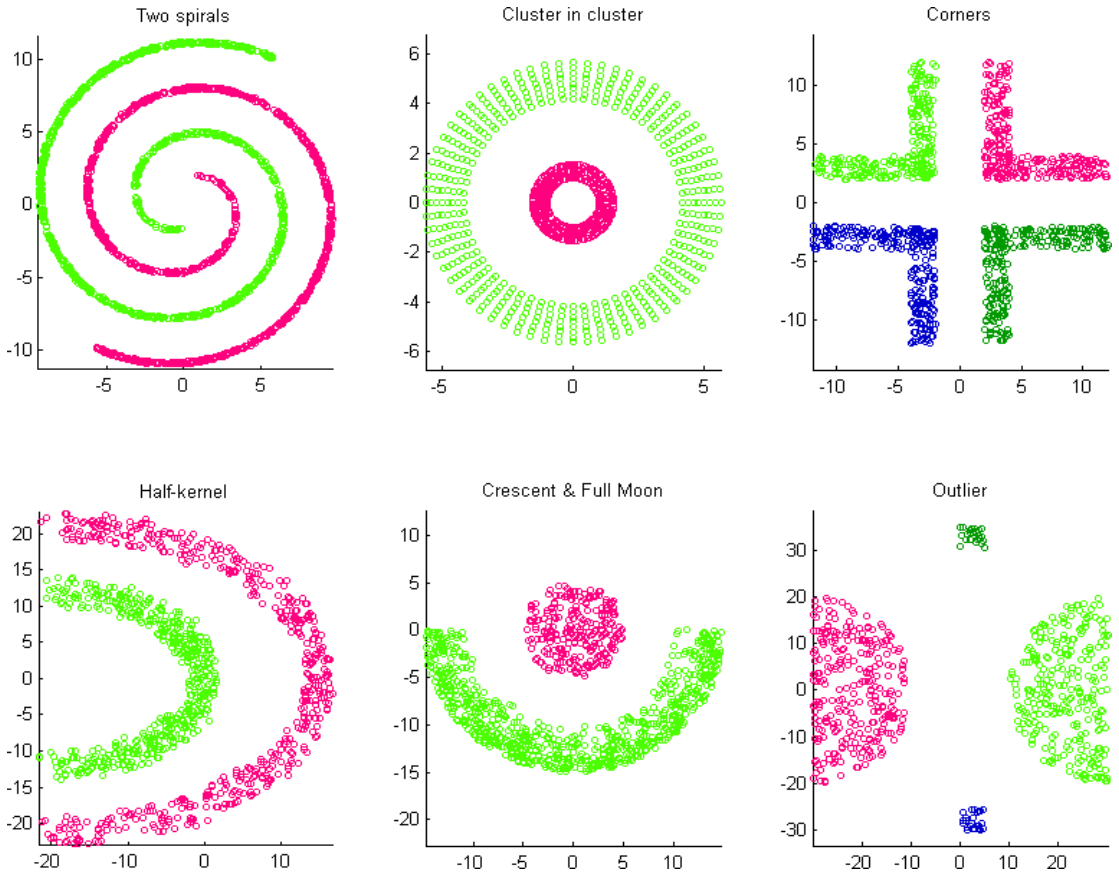
Impossible（不可能）

数据没有明显的结构或簇之间高度重叠时，无监督方法无法可靠地区分群体。

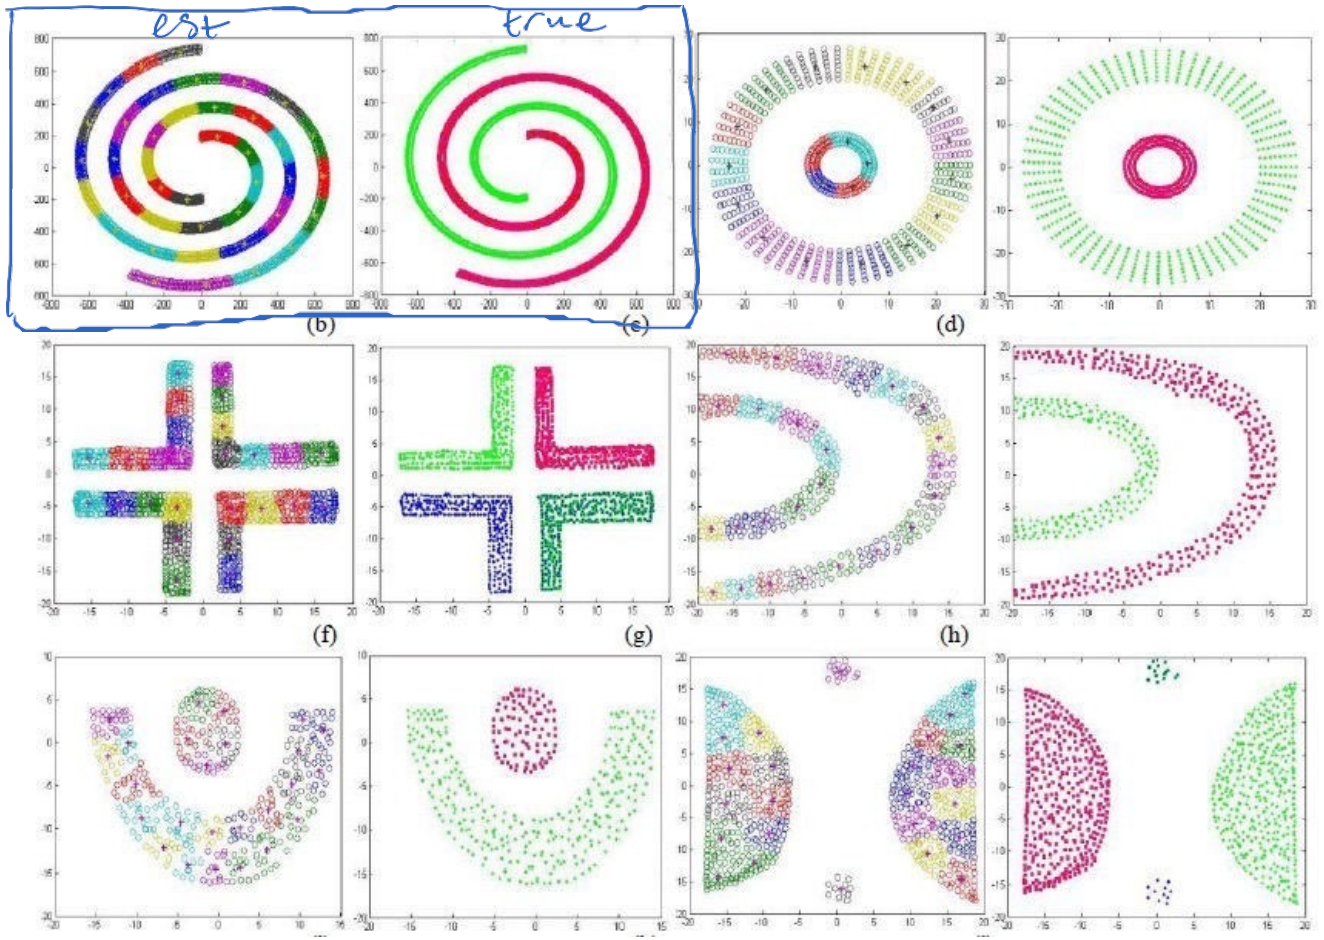
In Between（两者之间）

现实中最常见的情况：
数据有一定结构，但含噪声、不完全分离，需要模型具有更强的表示和鲁棒性。

其他（充满挑战的）簇结构示例



其他（充满挑战的）簇结构示例

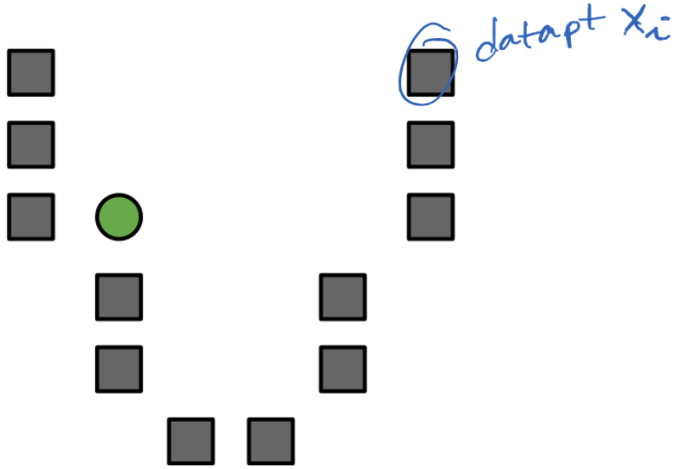


提纲

- 聚类方法的动机
- **聚类算法**
  - K-means聚类
  - K-means++聚类
- 聚类质量评估与簇数选择
- K-means的局限性与失效模式
- 混合模型：基于模型的聚类

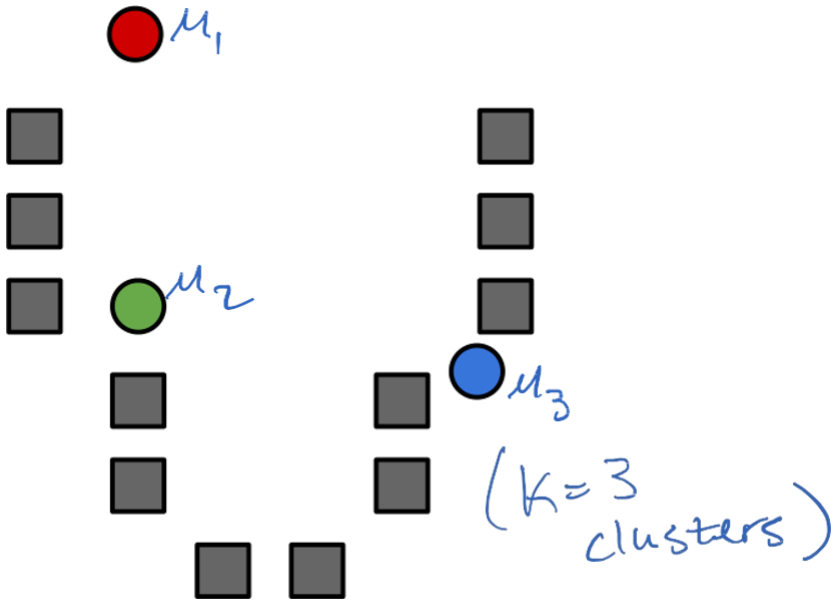
k-means聚类

- 目标
  - 将 n 个样本划分为K个簇
  - 使得同一簇内样本尽可能相似，不同簇之间尽可能不同
- 算法思想
  - 每个簇由一个中心（centroid）表示
  - 通过最小化样本到所属簇中心的平方距离和来优化聚类结果



k-means聚类

- 0. **初始化**：随机初始化K个簇中心 $\mu_1, \mu_2, \cdots, \mu_K$



k-means聚类

- 0. **初始化**：随机初始化K个簇中心 $\mu_1, \mu_2, \cdots, \mu_K$
- 1. **分配**：将每个样本分配给最近的簇中心

$$z_i \rightarrow argmin_{j \in \{1,2,\cdots,K\}} \|\mu_j - x_i\|^2$$

jth cluster center (fixed for now)

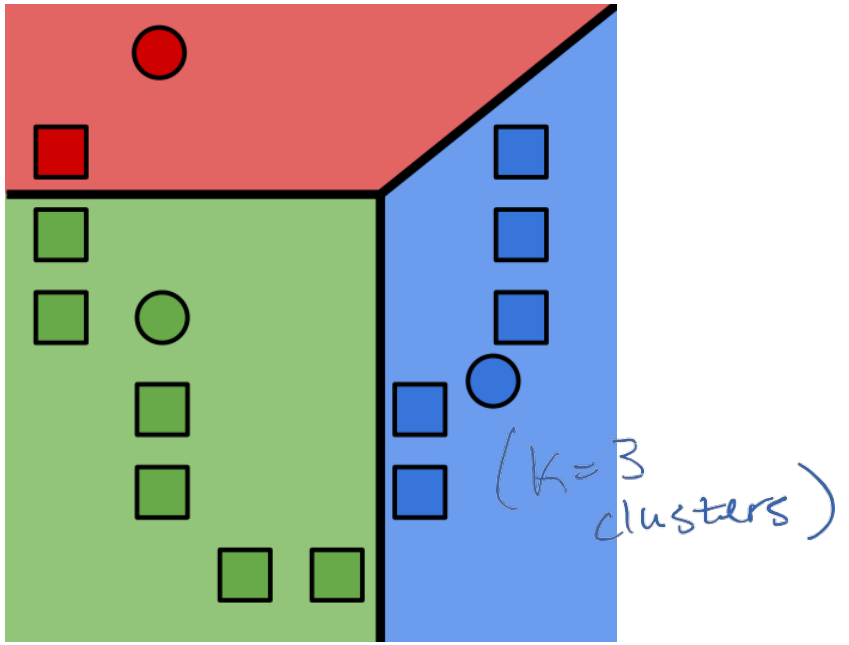
ith obs (fixed)

dist. b/t x_i and μ_j

Select the cluster index closest to x_i

推断标签

(inferred label)



k-means聚类

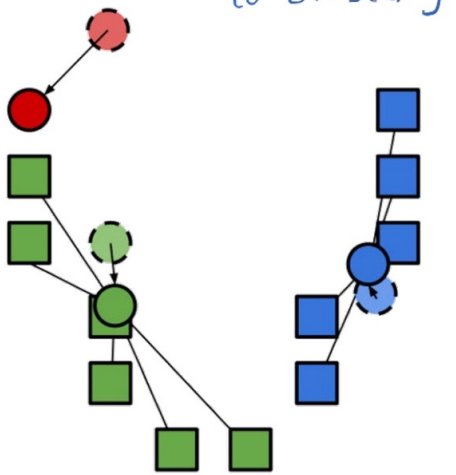
- 0. **初始化**：随机初始化K个簇中心$\mu_1, \mu_2, \cdots, \mu_K$
- 1. **分配**：将每个样本分配给最近的簇中心
- 2. **更新中心**：更新每个簇的中心为该簇中样本的均值

center of mass per cluster

$$\mu_j = \frac{1}{n_j} \sum_{i:z_i=j} x_i$$

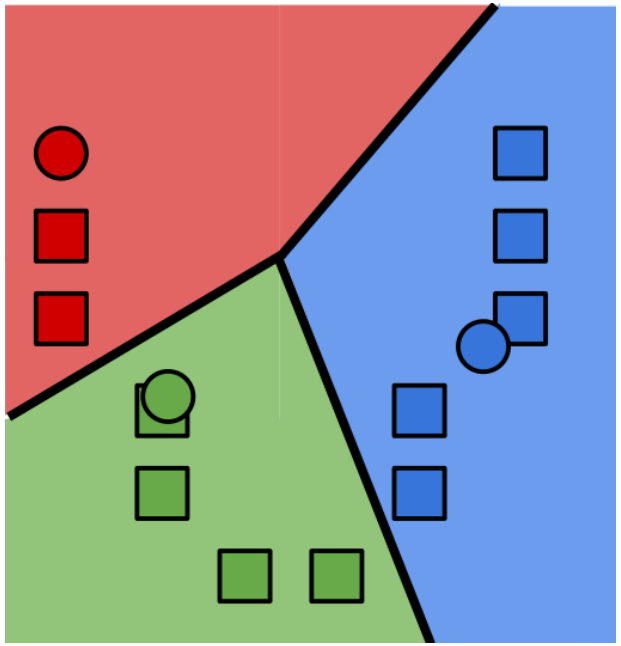
total # of obs in cluster j

all obs. assigned to cluster j



k-means聚类

- 0. **初始化**：随机初始化K个簇中心$\mu_1, \mu_2, \cdots, \mu_K$
- 1. **分配**：将每个样本分配给最近的簇中心
- 2. **更新中心**：更新每个簇的中心为该簇中样本的均值
- 3. **重复**：重复上述两步直到簇分配不再改变或收敛

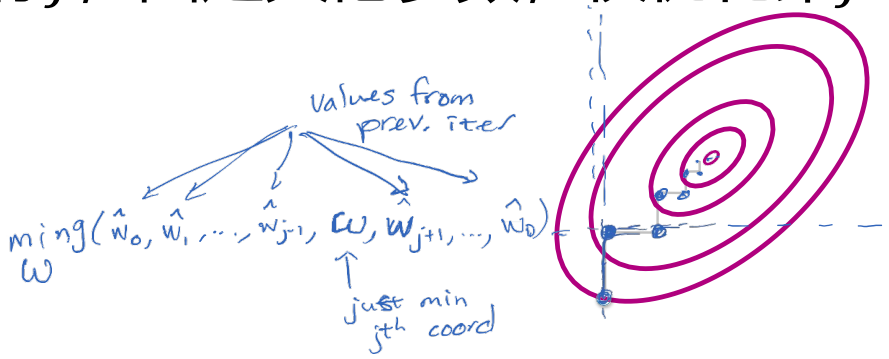


提纲

- 聚类方法的动机
- **聚类算法**
  - K-means聚类
    - K-means的坐标下降法
  - k-means++聚类
- 聚类质量评估与簇数选择
- K-means的局限性与失效模式
- 混合模型：基于模型的聚类

回顾：坐标下降

- 目标：最小化某个函数g
  - $\min_{w} g(w) \quad g(w) = g(w_0, w_1, \cdots, w_D)$
- 优化
  - 整体优化困难：一次性对所有参数求最优解往往复杂
  - 分坐标优化简单：若固定其他参数，仅对一个坐标优化通常容易
- 算法流程
  - 1. 初始化$\hat{w}$
  - 2. 循环更新：选择一个坐标j，固定其他参数，仅优化第j个分量



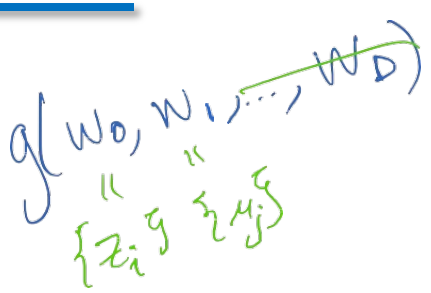
K-means与坐标下降法

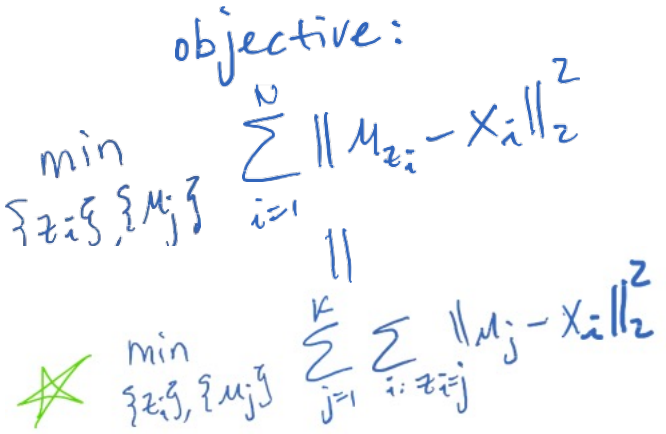
- 1. **分配**：将每个样本分配给最近的簇中心
  - $z_i \leftarrow arg\min_j \|\mu_j - x_i\|_2^2$
- 2. **更新中心**：更新每个簇的中心为该簇中样本的均值
  - $\mu_j = \frac{1}{n_j}\sum_{i:z_i=j} x_i$
  - $\mu_j \leftarrow arg\min_\mu \sum_{i:z_i=j}\|\mu - x_i\|_2^2$

等价于

K-means与坐标下降法

- 1. **分配**：将每个样本分配给最近的簇中心
  - $z_i \leftarrow arg\min_j \|\mu_j - x_i\|_2^2$
- 2. **更新中心**：更新每个簇的中心为该簇中样本的均值
  - $\mu_j \leftarrow arg\min_\mu \sum_{i:z_i=j} \|\mu - x_i\|_2^2$





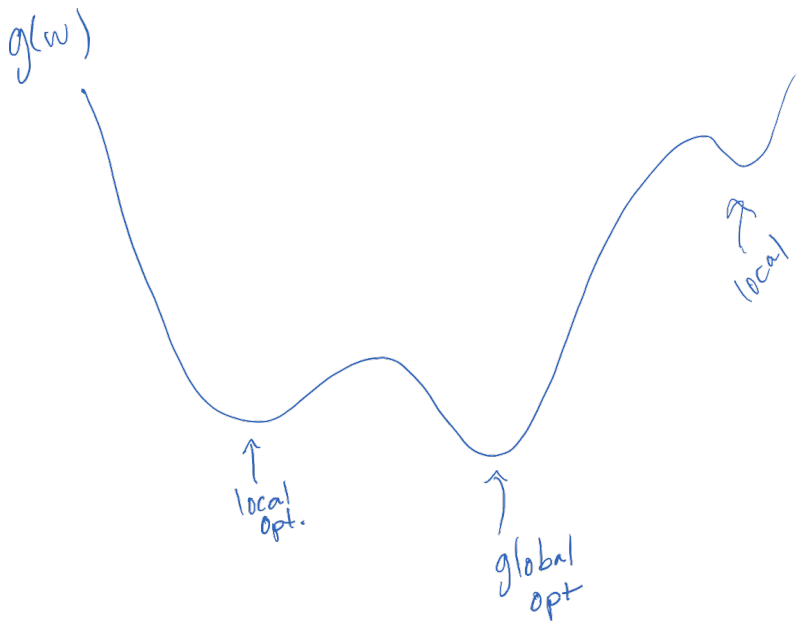
K-means与坐标下降法

- 1. **分配**：将每个样本分配给最近的簇中心
  - $z_i \leftarrow arg\min_j \left\|\mu_j - x_i\right\|_2^2$
- 2. **更新中心**：更新每个簇的中心为该簇中样本的均值
  - $\mu_j \leftarrow arg\min_\mu \sum_{i:z_i=j} \|\mu - x_i\|_2^2$

交替最小化
1. 优化z，固定μ；2.优化μ，固定z
= 在两个坐标子空间上进行坐标下降

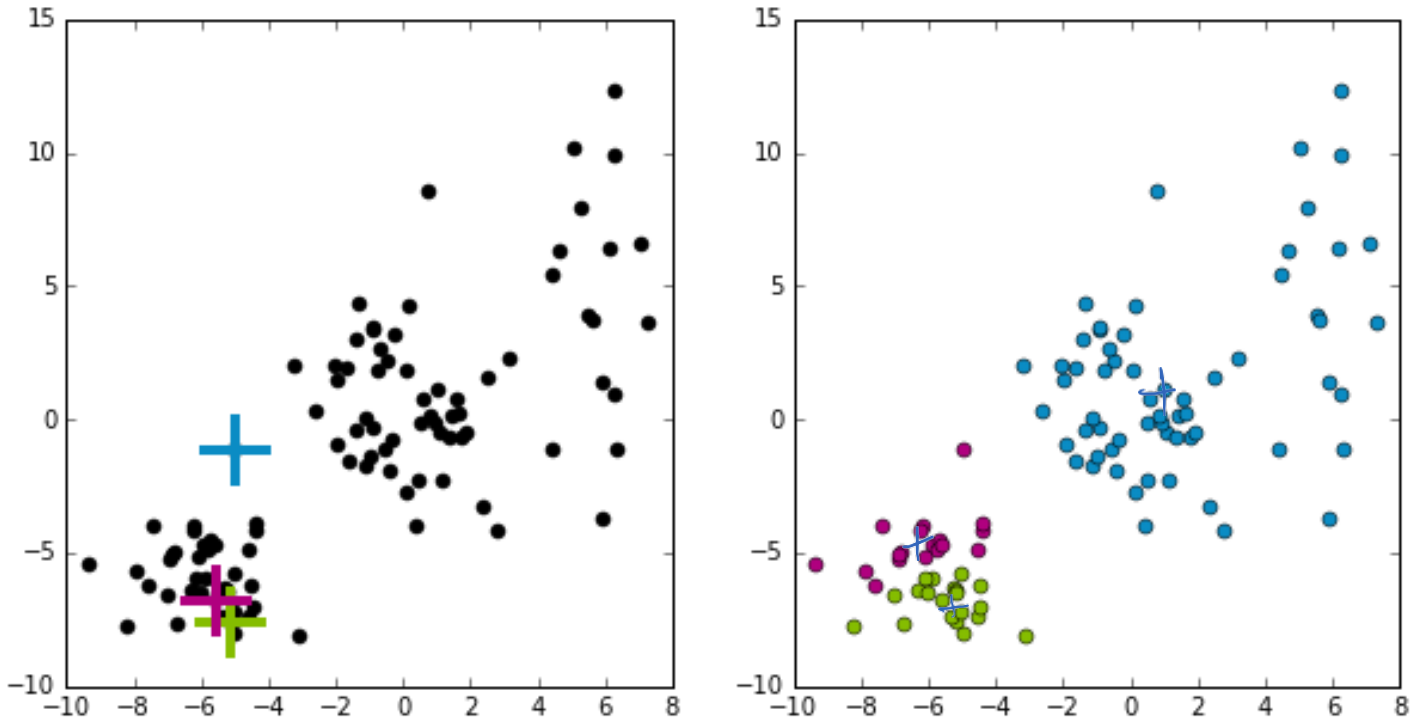
K-means的收敛性

- J= 簇内距离平方和（有界性：值始终非负）
- 交替最小化（单调下降：每一步都不增加目标函数值）：
  - 分配：固定μ，重新分配样本→使J不增大
  - 更新中心：固定z，更新μ为均值→使J进一步下降
- 单调下降+有界性 =>目标函数值收敛
  - 但不保证全局最优



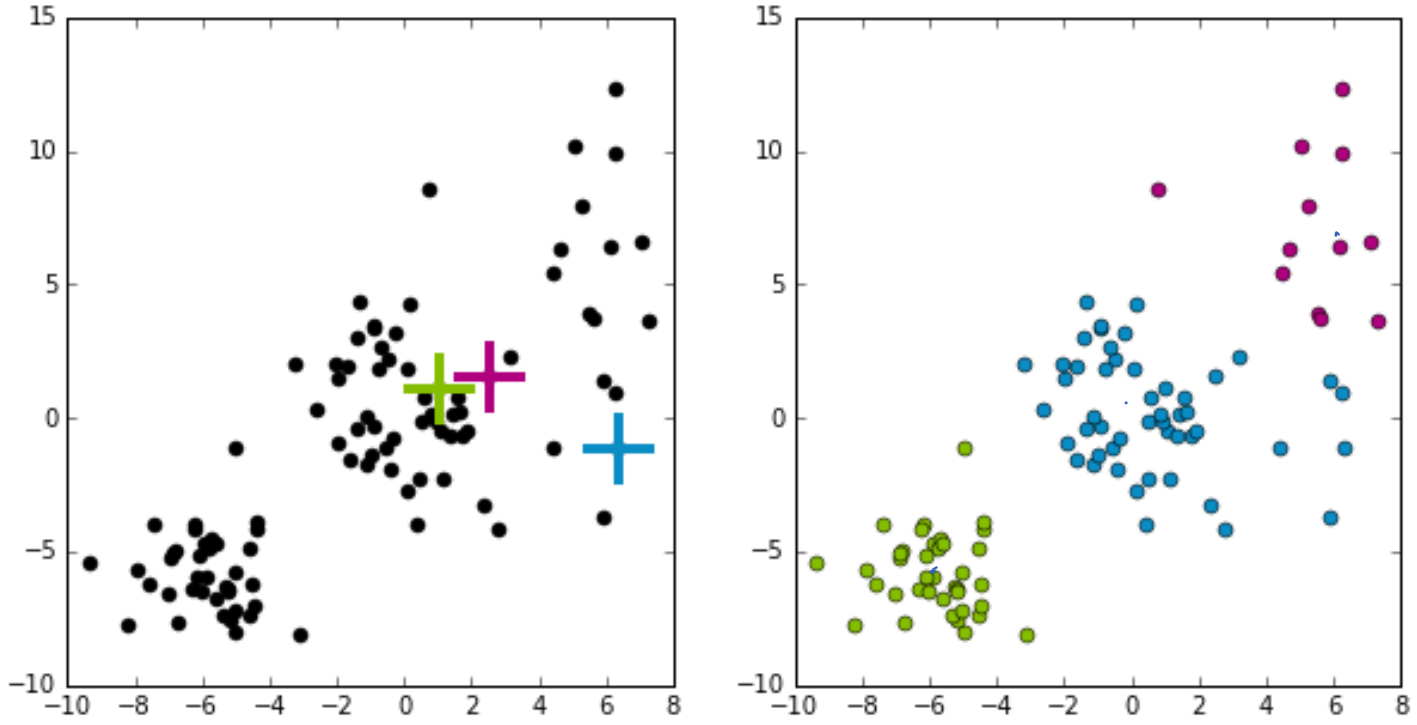
K-means的收敛性

- 收敛的解取决于初始中心位置，不保证找到全局最优解



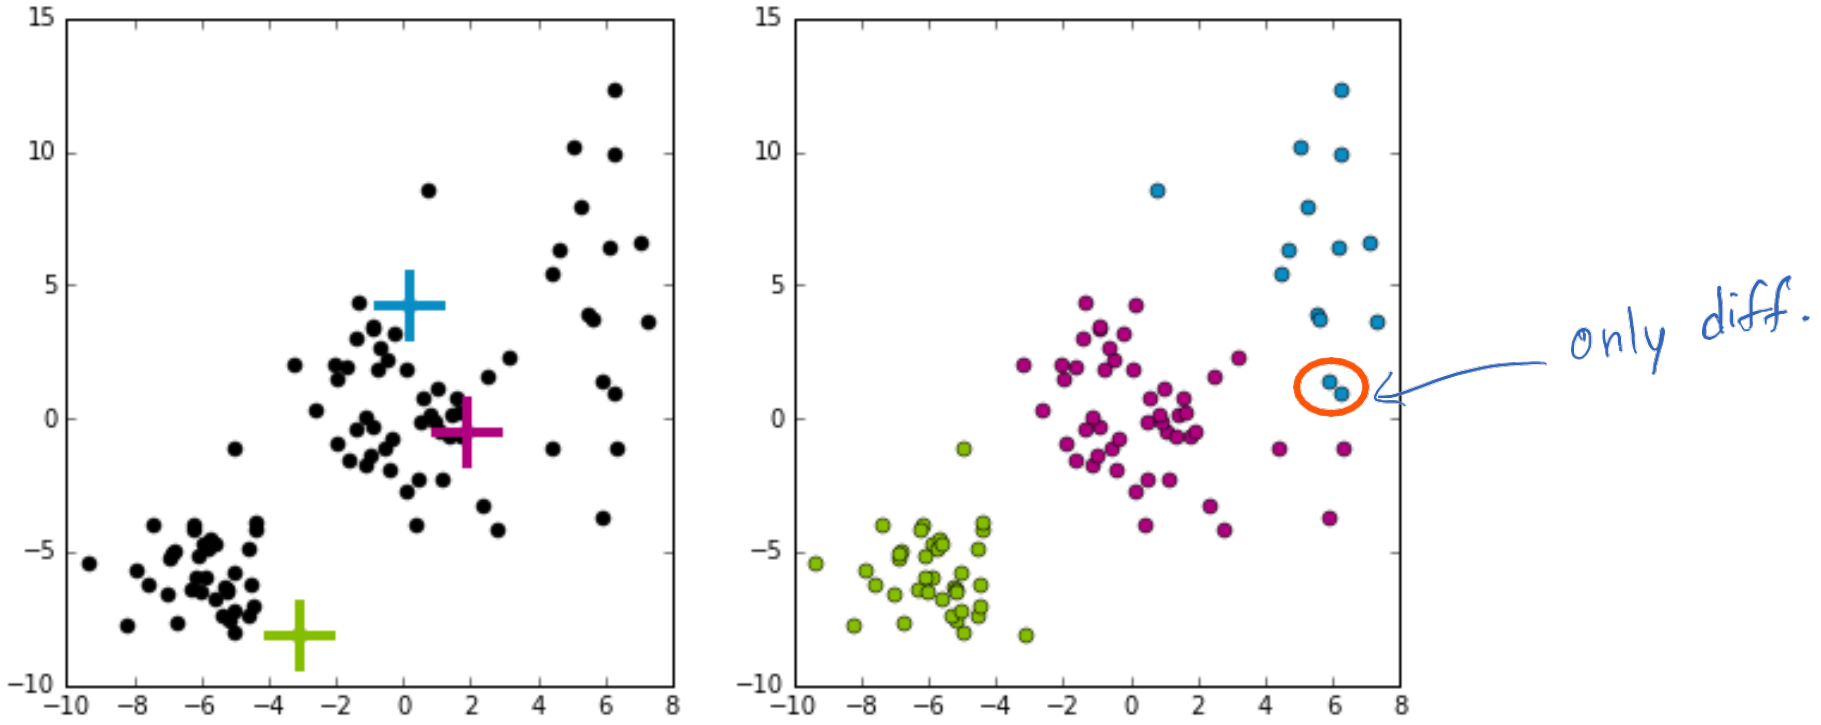
K-means的收敛性

- 收敛的解取决于初始中心位置，不保证找到全局最优解



K-means的收敛性

- 收敛的解取决于初始中心位置，不保证找到全局最优解



提纲

- 聚类方法的动机
- **聚类算法**
  - K-means聚类
  - K-means++聚类
    - K-means++初始化
- 聚类质量评估与簇数选择
- K-means的局限性与失效模式
- 混合模型：基于模型的聚类

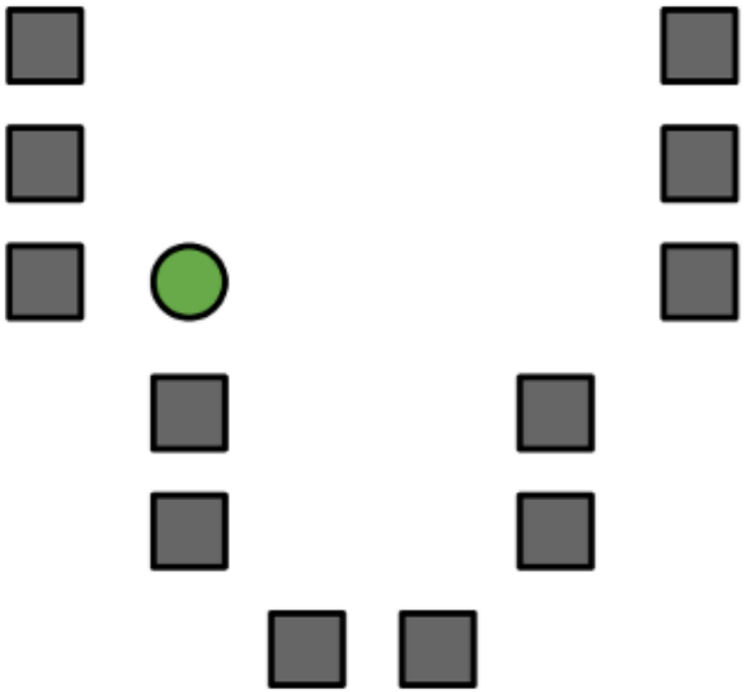
K-means++概述

- 随机初始化的K-means可能导致
  - 多个中心点靠得太近
  - 收敛到局部最优
  - 聚类结果不稳定
- K-means++通过更“聪明”的初始化方式来改善这些问题
  - K-means++的核心思想：通过概率引导的初始化，让初始中心彼此分散，从而提高最终聚类质量

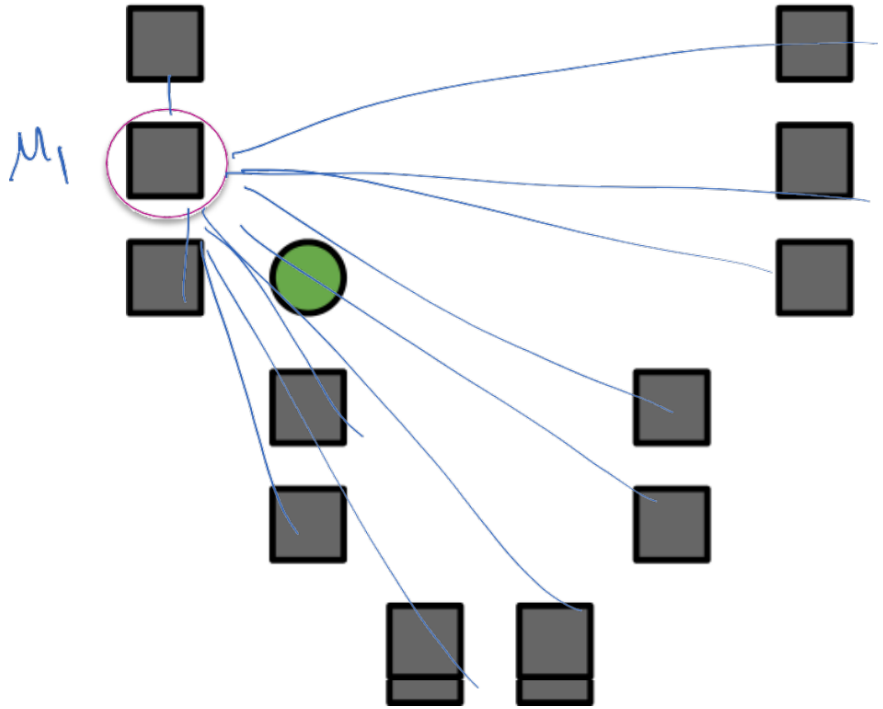
K-means++概述

- 随机选取一个样本作为第一个中心μ_1
- 已有 t个中心时，对于每个样本x_i，计算它到最近已选中心的距离平方：
  - $D^2(x_i) = \min_{1 \le j \le t} \|\mu_j - x_i\|^2$
- 以$D^2(x_i)$作为抽样权重，随机选择下一个中心
  - 离已选中心越远的点被选为新中心的概率越高
- 重复前两个直到选出K个初始中心
- 以这些中心为起点，运行标准K-means

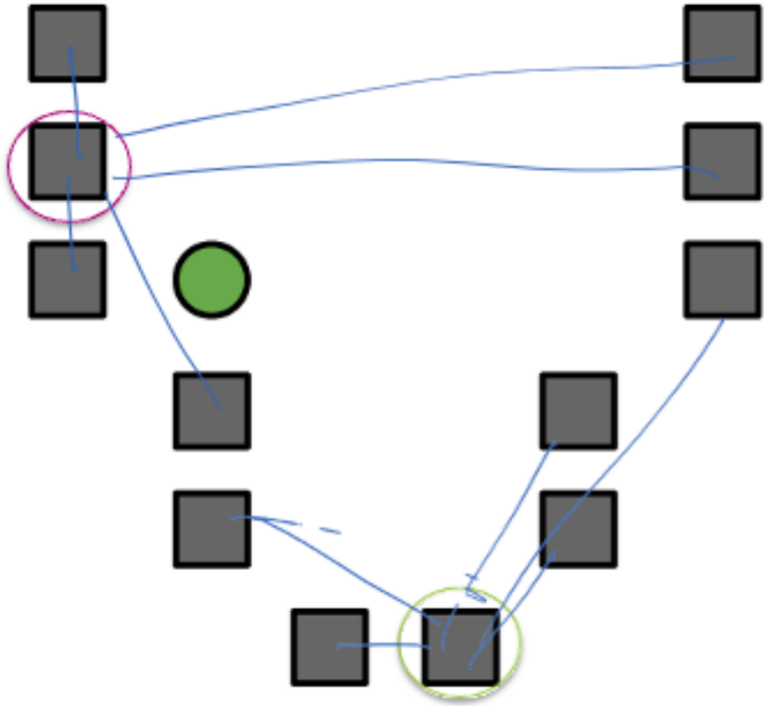
K-means++可视化



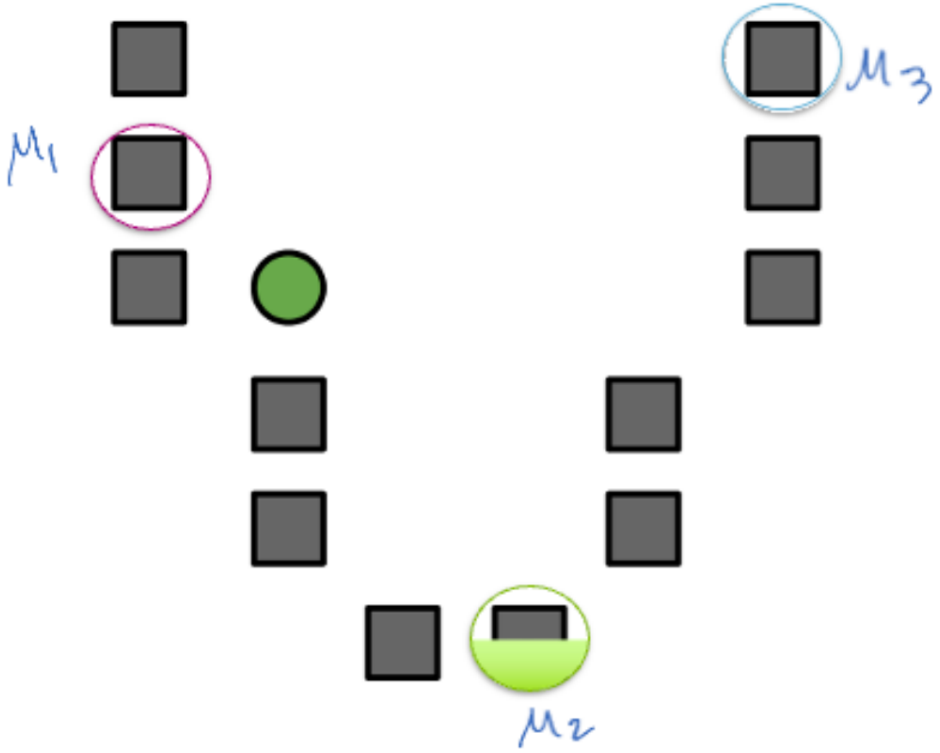
K-means++可视化



K-means++可视化



K-means++可视化

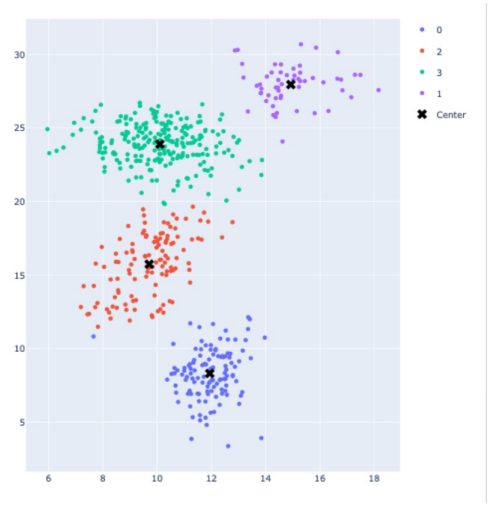


K-means++优缺点

- 优点
  - 更好的初始化：初始中心点分布更分散，避免多个中心重叠
  - 更快收敛：起点更接近全局最优，通常需要更少迭代
  - 更稳定结果：不同运行间结果差异较小，鲁棒性更高
  - 简单易用：仅在初始化阶段多做几步，代价极小
- 缺点
  - 额外计算开销：初始化阶段需多次计算距离平方
  - 仍非全局最优：只能提高概率，不能彻底避免局部最优
  - 对异常点敏感：离群点可能被选为初始中心

聚类结果的解读

- 聚类能够发现数据中的模式，但聚类结果不一定具有明确的现实含义
  - 一位骑行者记录了每次骑行的速度和骑行时长，但没有记录每次使用的是哪一辆自行车
    - 使用K-means算法，将所有骑行记录划分为K个簇。
    - 但我们并不知道每个簇分别对应哪一辆自行车。
    - 每个簇是否代表一辆自行车？
      - 不一定
      - 聚类结果也可能反映其他因素，例如团体骑行、交通状况等









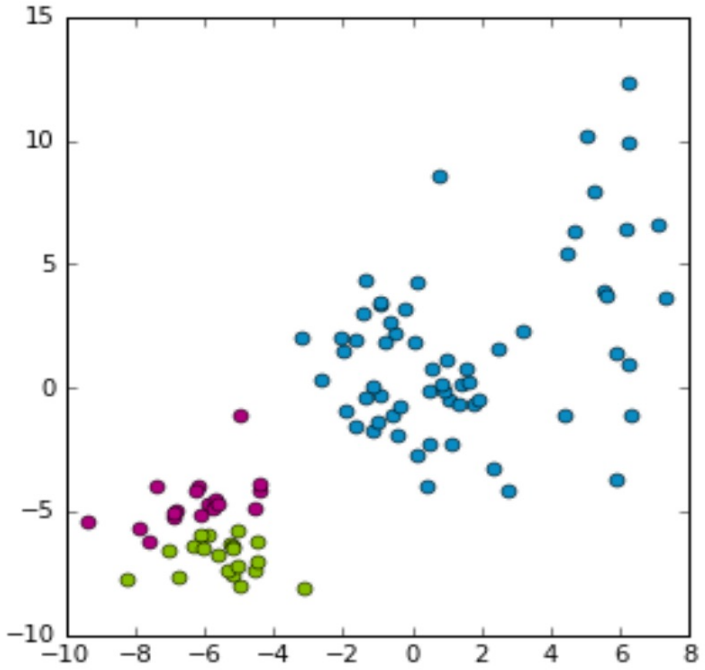


提纲

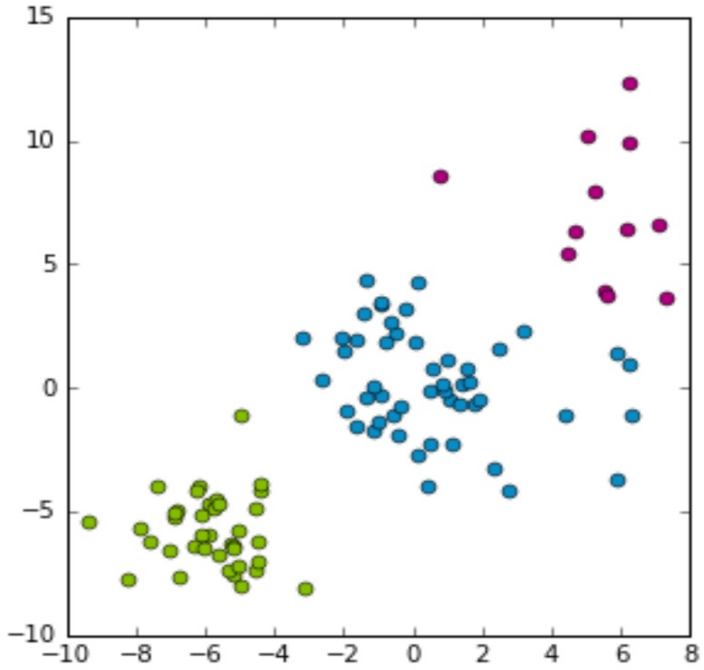
- 聚类方法的动机
- 聚类算法
- **聚类质量评估与簇数选择**
- K-means的局限性与失效模式
- 混合模型：基于模型的聚类

哪个更好?

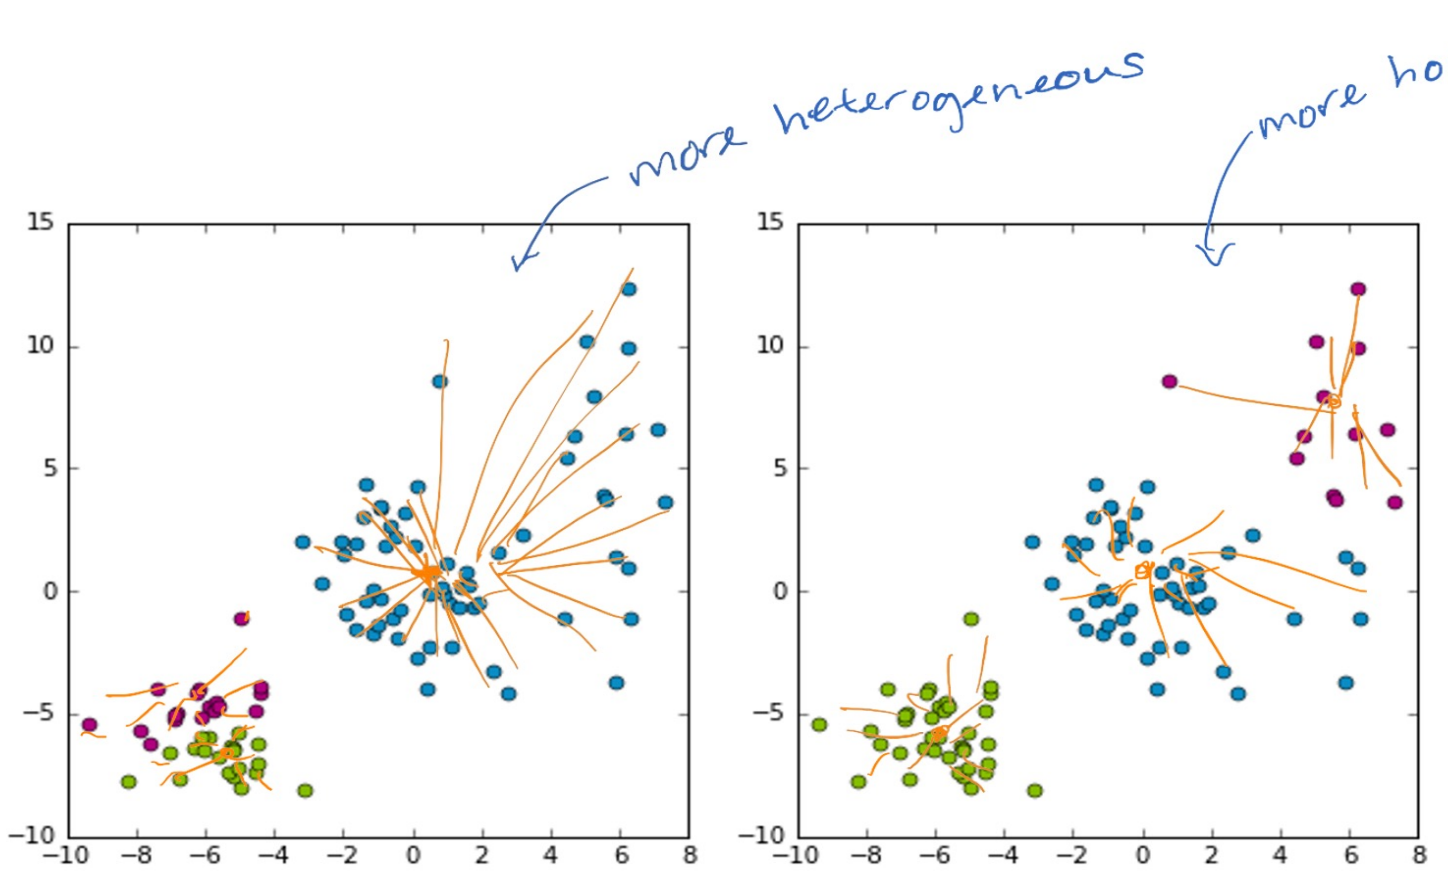
Option A



Option B



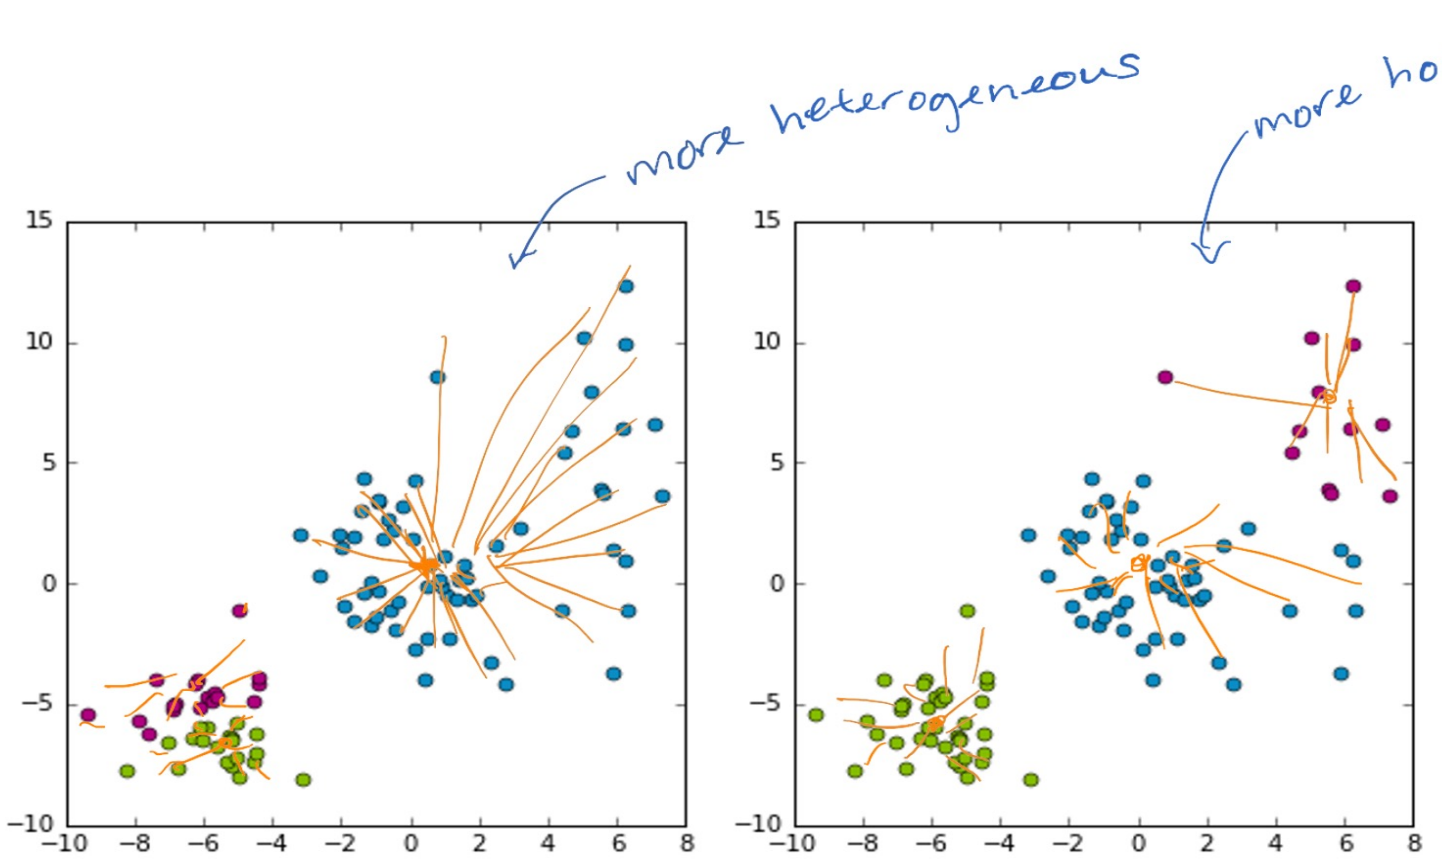
K-means目标函数



K-means聚类
通过最小化样本到其所属簇中心的平方距离之和来确定簇结构

$$\sum_{j=1}^{k} \sum_{i:z_i=j} \|\mu_j - x_i\|_2^2$$

簇内异质性



可以用来衡量聚类的质量

$$\sum_{j=1}^{k} \sum_{i:z_i=j} \|\mu_j - x_i\|_2^2$$

簇内异质性：簇中样本彼此之间的不相似程度

- **异质性越小→簇内样本越接近→聚类效果越好**
- **异质性越大→样本分散、结构不明显**

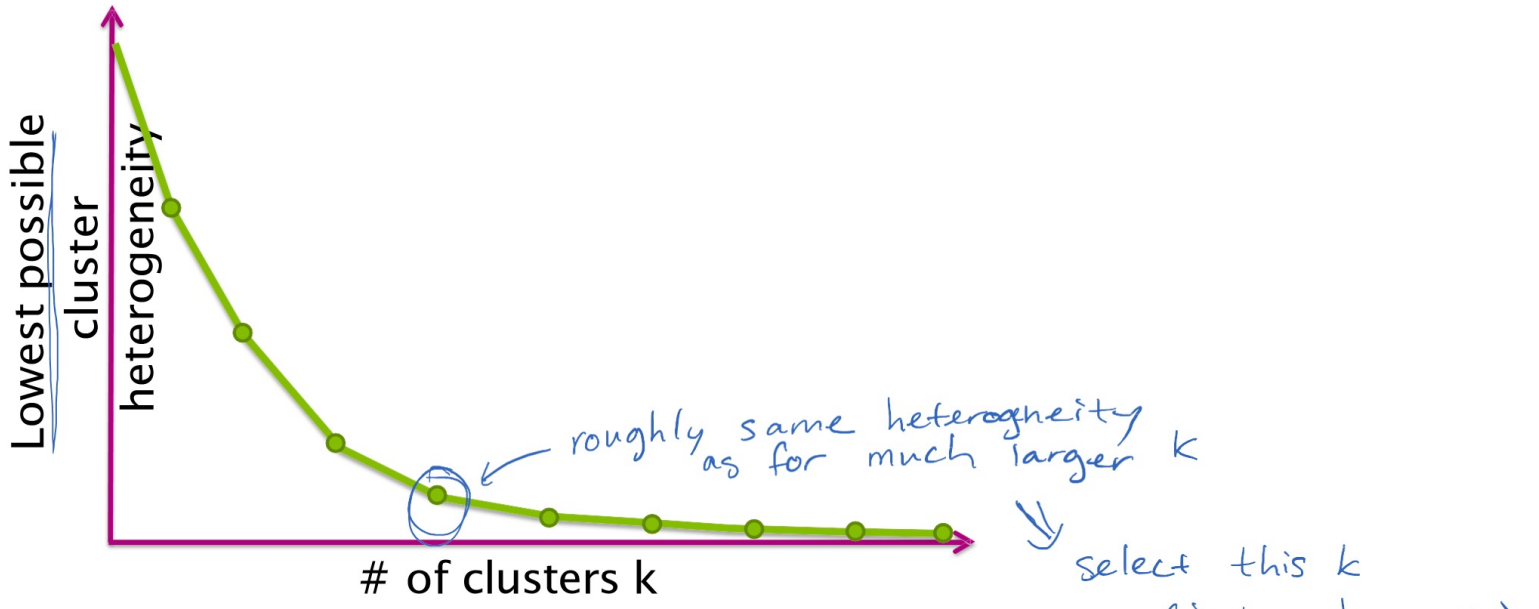
当簇数K增加时会发生什么?

- 随着K增加，簇的数量增多，模型可以更细致地拟合数据
  - 每个簇的异质性 (heterogeneity) 会下降
  - 簇更能“贴合”数据中的局部结构
- 但同时也意味着模型可能出现过拟合：
  - 过度细分数据，失去泛化意义。
- 极端情况：当簇数等于样本数时K=N
  - 每个样本都可以成为一个簇中心：heterogeneity=0
  - 所有样本都完全拟合，没有误差

最小可能的簇内异质性随K增大而降低，需要在 “模型复杂度”与“聚类解释性”之间找到平衡

如何选择合适的簇数K

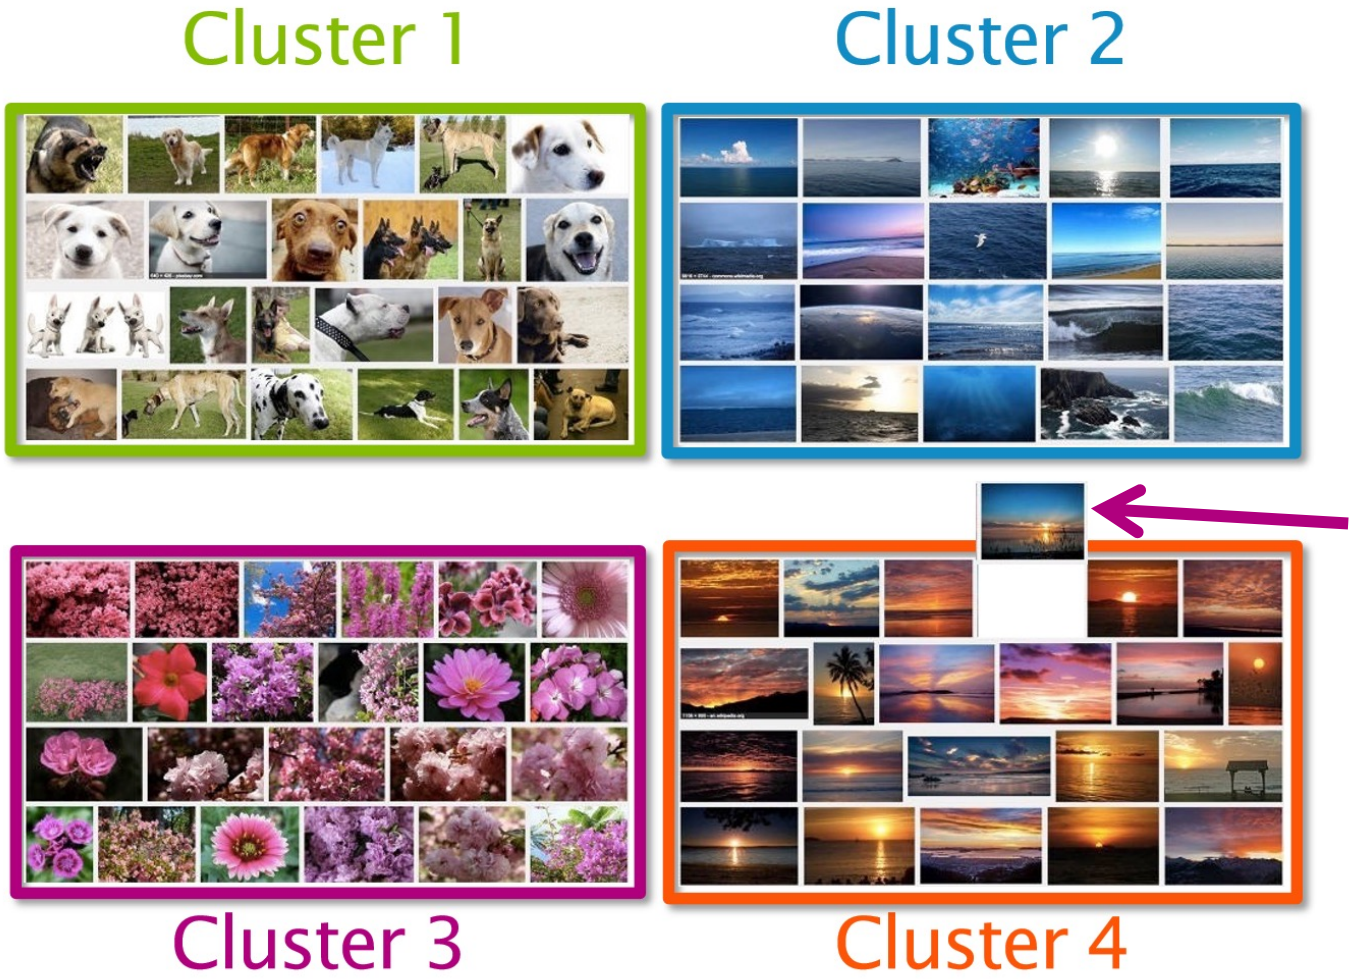
- Elbow Method（肘部法）
  - 绘制不同K下的聚类代价（如簇内平方距离）
  - 观察曲线的“肘部”，即下降趋势显著减缓的点
    - 该点的K是较好的选择（直觉：增加K不再显著减少误差时，停止增加）



提纲

- 聚类方法的动机
- 聚类算法
- 聚类质量评估与簇数选择
- **K-means的局限性与失效模式**
- 混合模型：基于模型的聚类

聚类分配中的不确定性



K-means对每个样本进行硬分配（hard assignment）：

- 每个点被分配到唯一的簇
- 无法表达“不确定性”或“隶属度”
- 对边界附近的样本特别脆弱

聚类分配中的不确定性

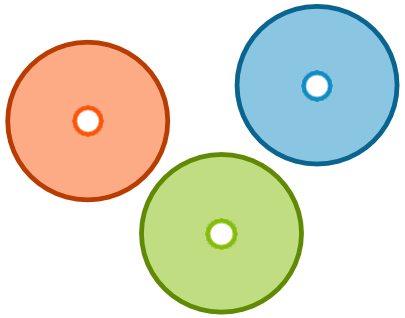
- 机器学习的最终目标是推断（Inference）—— 做出预测
  - 预测本身具有不确定性
  - 不确定性的来源/类型
    - 认知不确定性（Epistemic Uncertainty (Reducible)）：由训练数据集有限以及建模过程所引起的系统性不确定性
    - 偶然不确定性（Aleatoric Uncertainty (Irreducible)）：由训练数据中的观测噪声所引起的不确定性
- 需要一种描述不确定性的框架 —— 概率

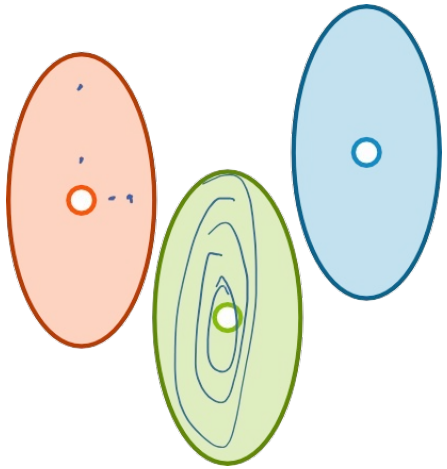
K-means的其他局限性

- $z_i = arg\min_j \|\mu_j - x_i\|_2^2$

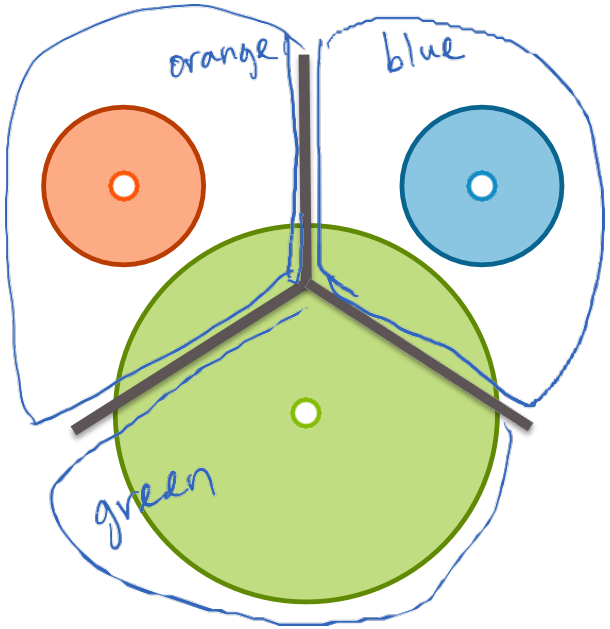
只用中心来代表整个簇

- 无法捕捉**簇内部的形状、方向或方差结构**
- **对非对称分布或拉长分布的簇**表现不佳

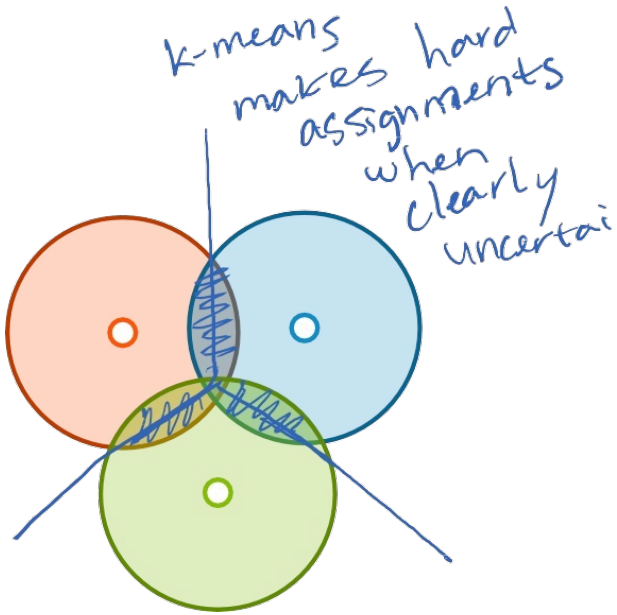




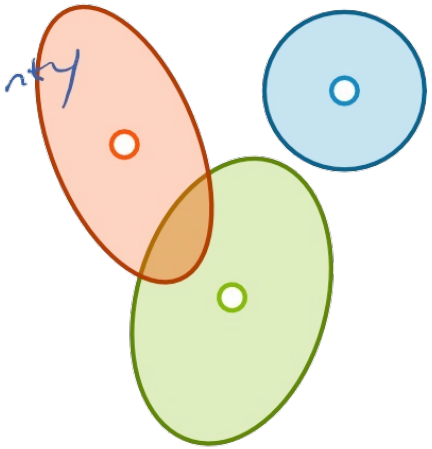
K-means的其他局限性



类簇大小有差别



重叠性类簇



不同形状/方向的类簇

K-means总结

- 描述聚类算法的输入（无标签观测数据）与输出（聚类标签）
- 判断一个任务是监督学习还是无监督学习
- 使用K-means对观测数据进行聚类
- 将K-means表述为一种坐标下降算法并讨论其收敛性
- 描述聚类算法的典型应用场景

提纲

- 聚类方法的动机
- 聚类算法
- 聚类质量评估与簇数选择
- K-means的局限性与失效模式
- **混合模型：基于模型的聚类**

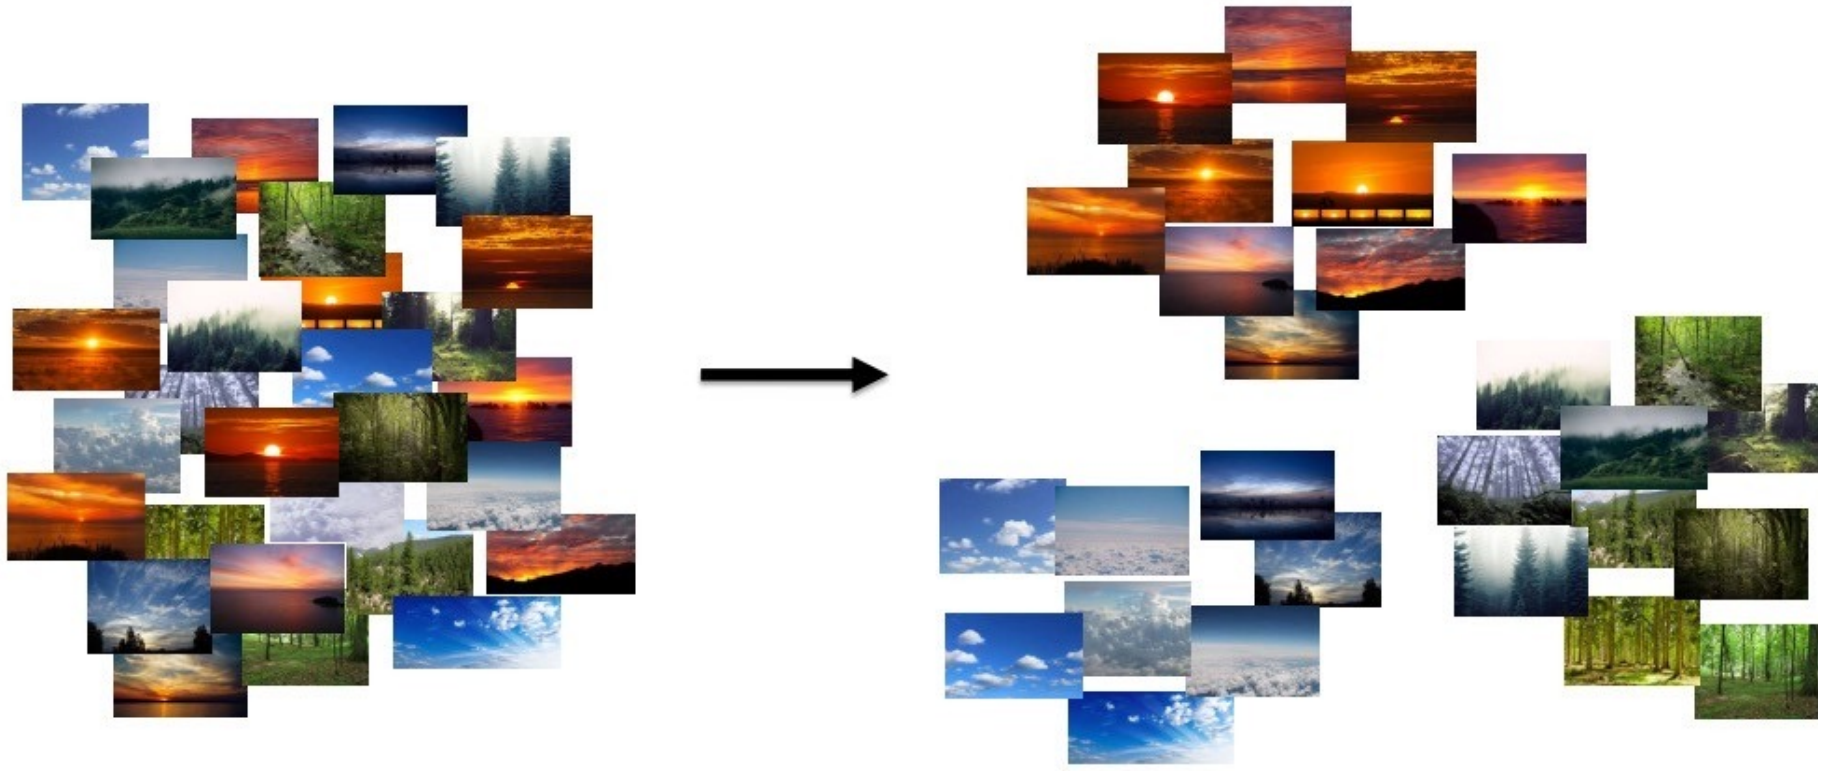
引出概率模型：混合模型

- 提供软分配
  - 不再强制每个样本只能属于一个簇，而是为每个样本提供属于各簇的概率
    - 例：图片属于类别的概率为54% clouds，45% sunset，1% dog，0% pink flower
- 能刻画簇形状，而非只看中心
  - 允许每个簇具有不同的形状、方向和方差
  - 不再假设球形簇→能处理椭圆形、拉伸、多方向结构的数据
- 可学习特征的不同重要性
  - 可以自动学习每维特征的重要性
  - 相当于自动学习“在分配簇时每个特征的权重”

混合模型

- 混合模型将聚类视为一个生成过程（generative process）
  - 数据由多个潜在概率分布（latent components）生成
  - 每个分布代表一个簇
  - 聚类目标：推断每个样本属于哪个分布（簇）

案例研究：图像聚类



图片的简单表示

- 考虑红色、绿色、蓝色像素的平均强度

$x_i \in \mathbb{R}^3$



[R = 0.05, G = 0.7, B = 0.9]



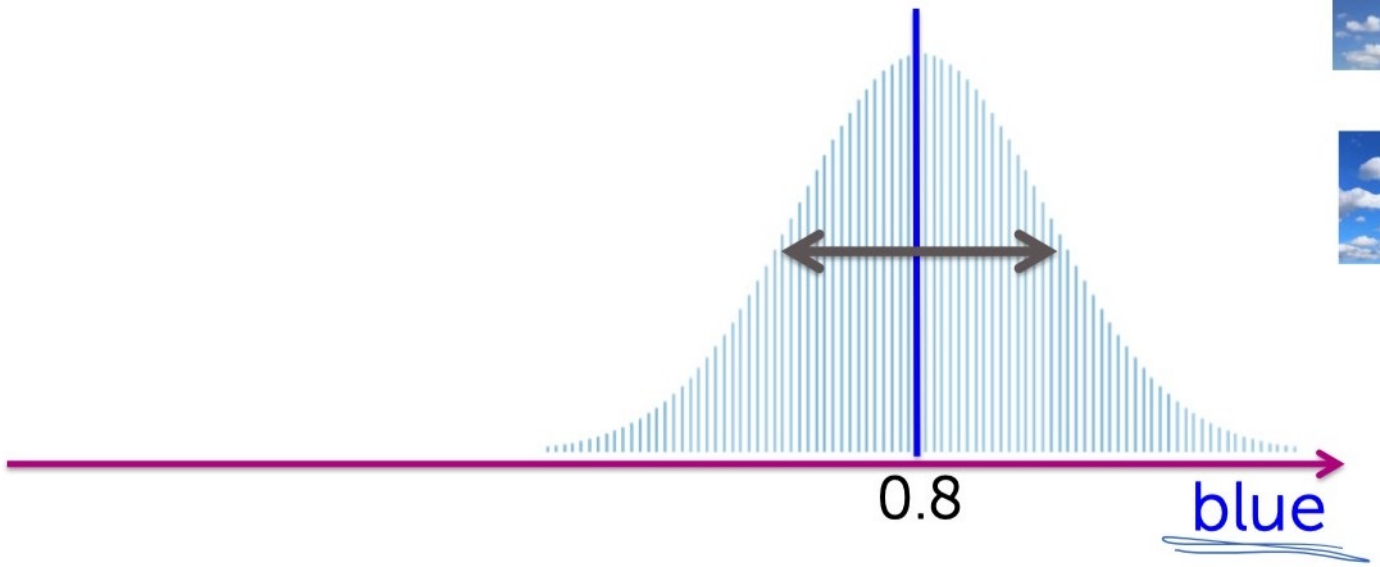
[R = 0.85, G = 0.05, B = 0.35]



[R = 0.02, G = 0.95, B = 0.4]

所有“云朵”图像的分布

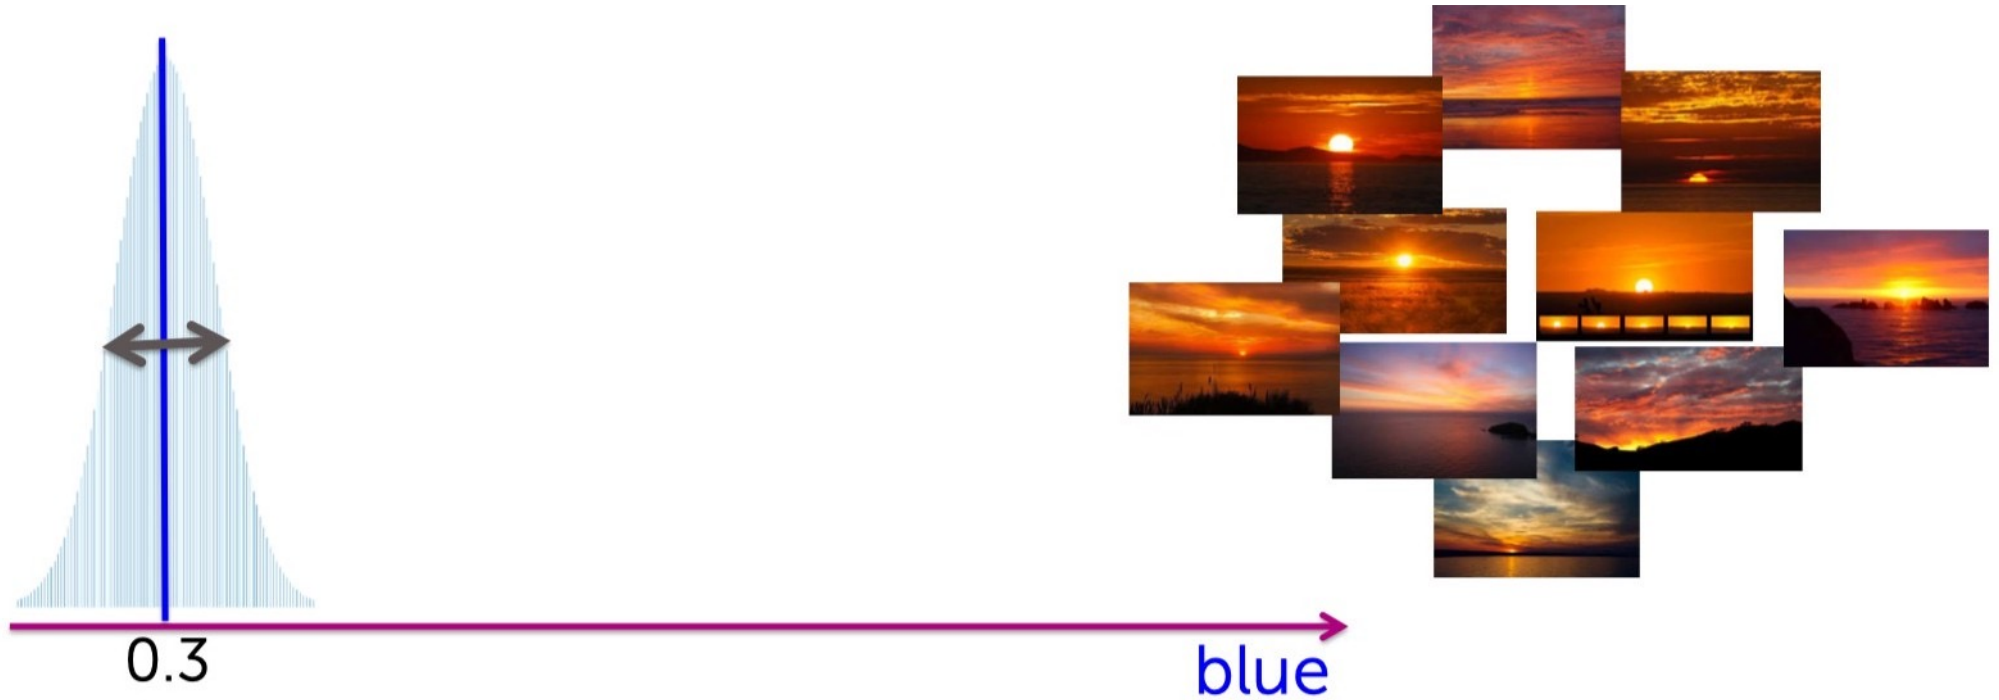
- 首先聚焦于蓝色维度





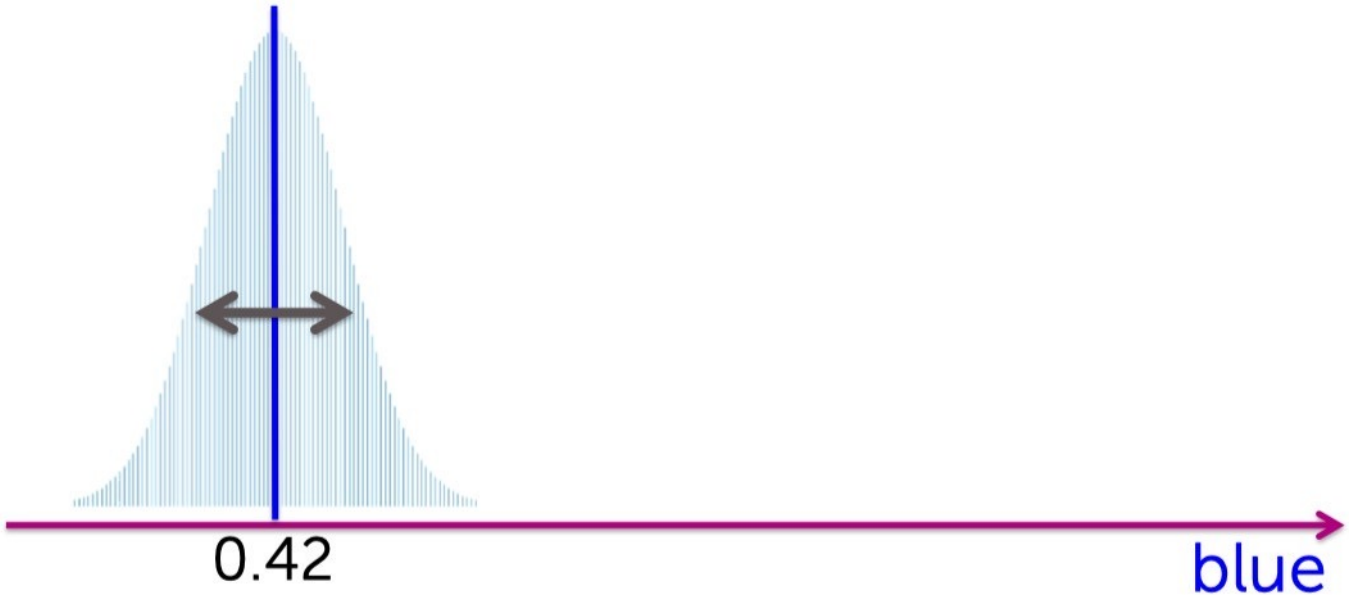
所有“落日”图像的分布

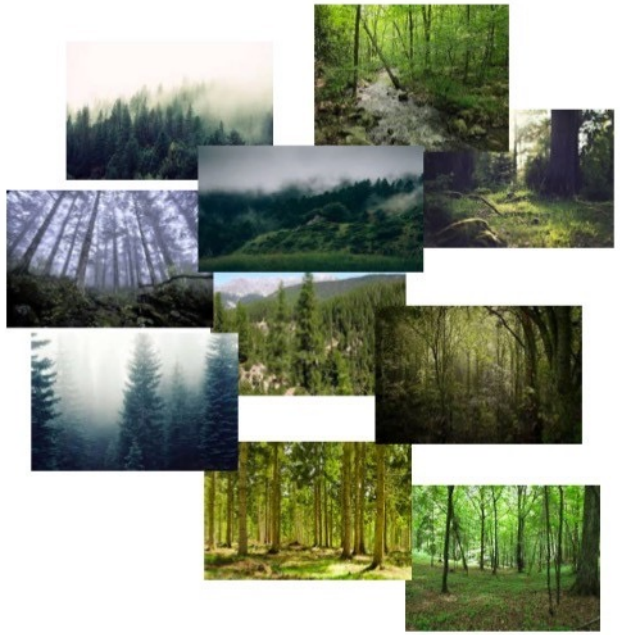
- 首先聚焦于蓝色维度



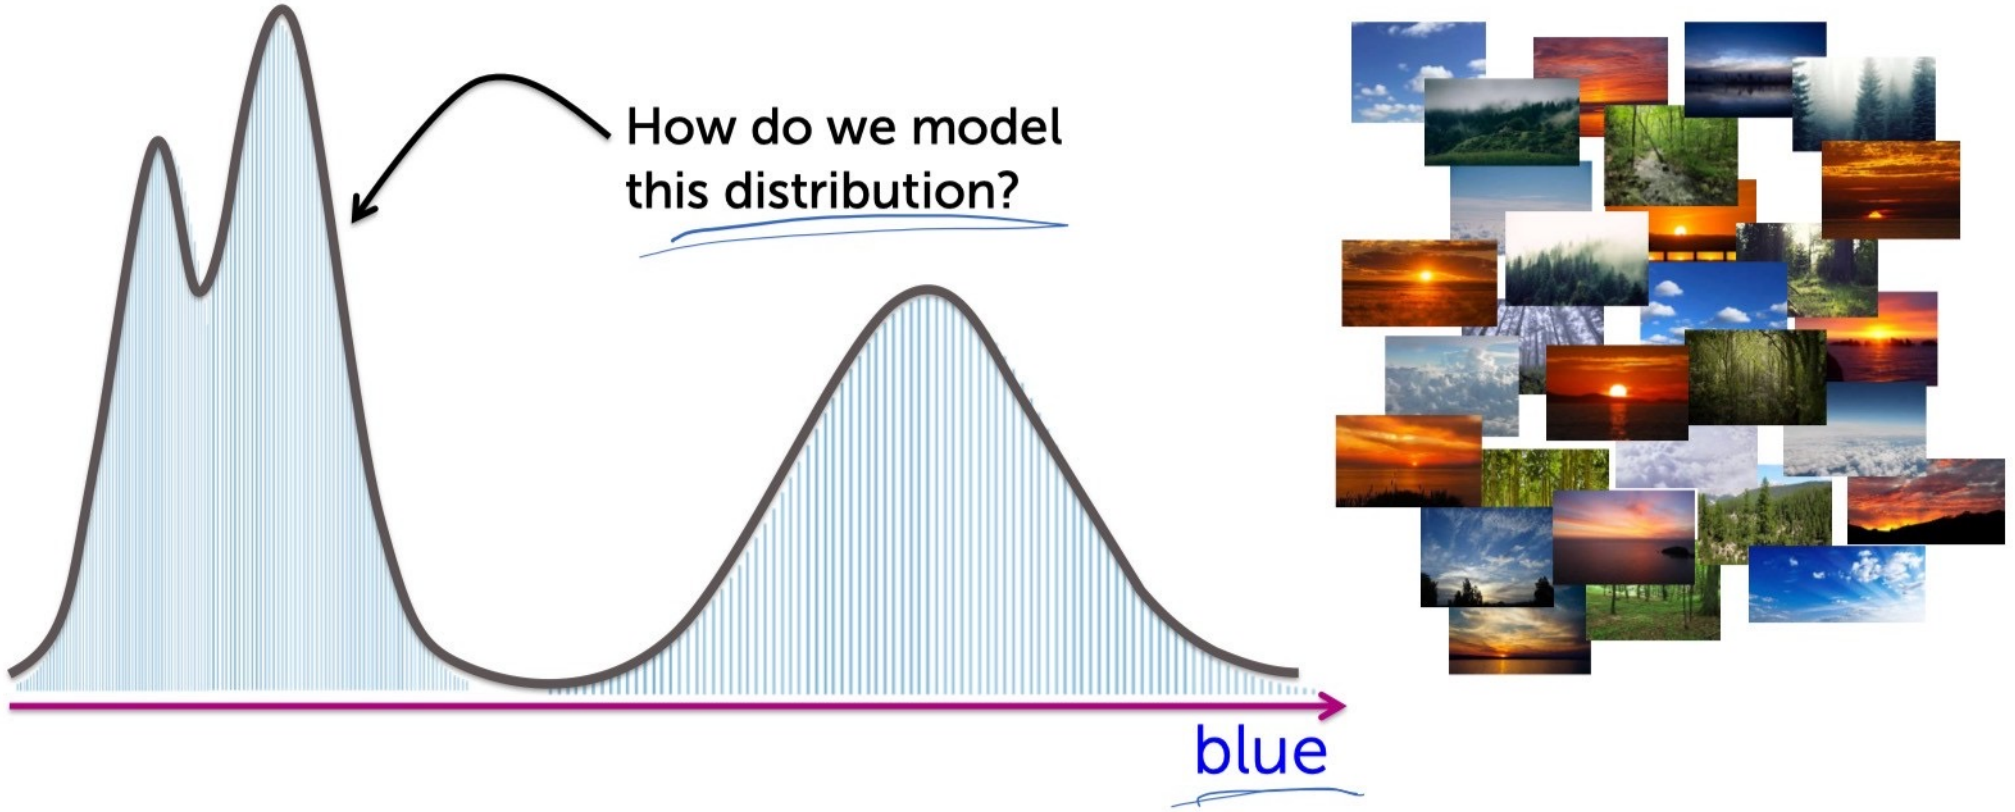
所有“森林”图像的分布

- 首先聚焦于蓝色维度





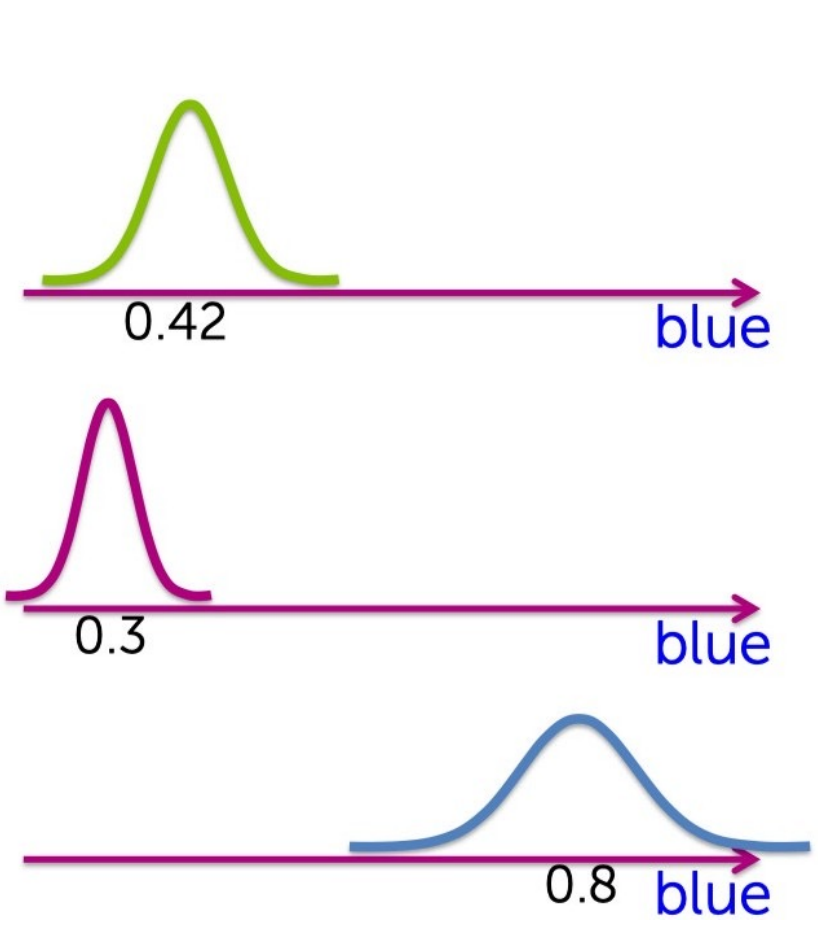
所有图像的分布

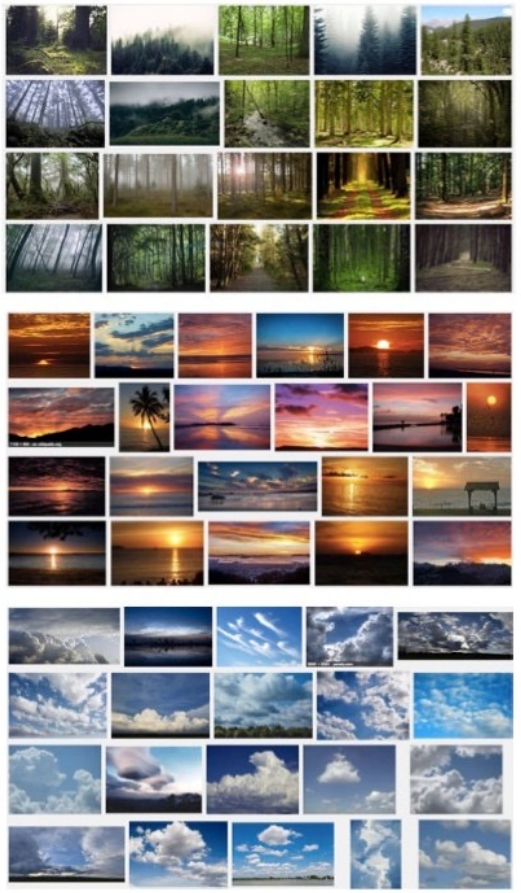


提纲

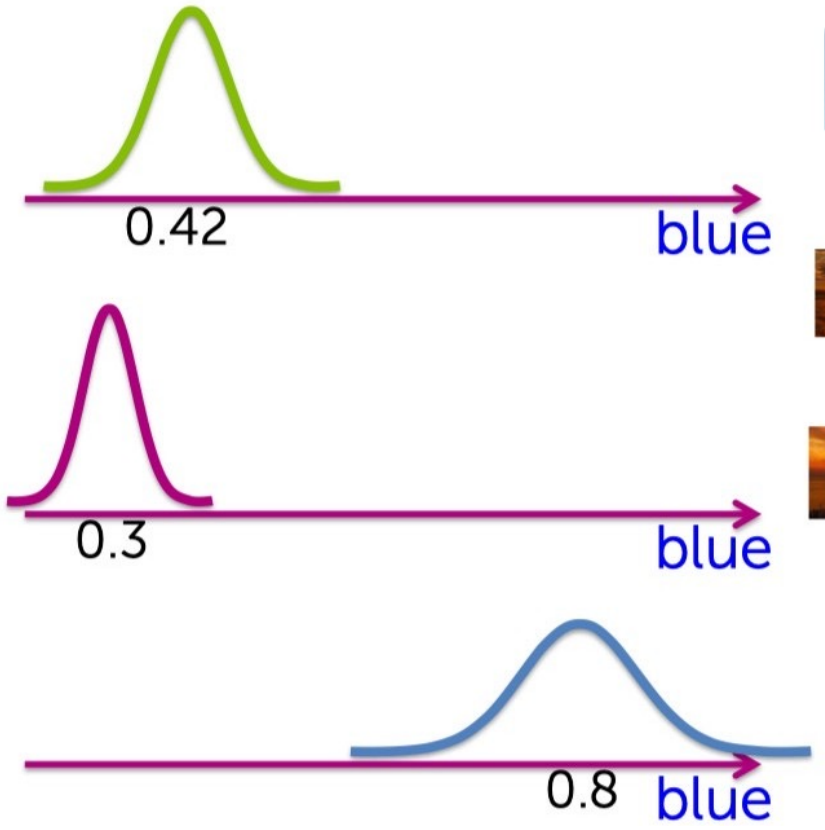
- 聚类方法的动机
- 聚类算法
- 聚类质量评估与簇数选择
- K-means的局限性与失效模式
- **混合模型：基于模型的聚类**
  - 高斯混合建模

对于每个簇，建模为高斯分布



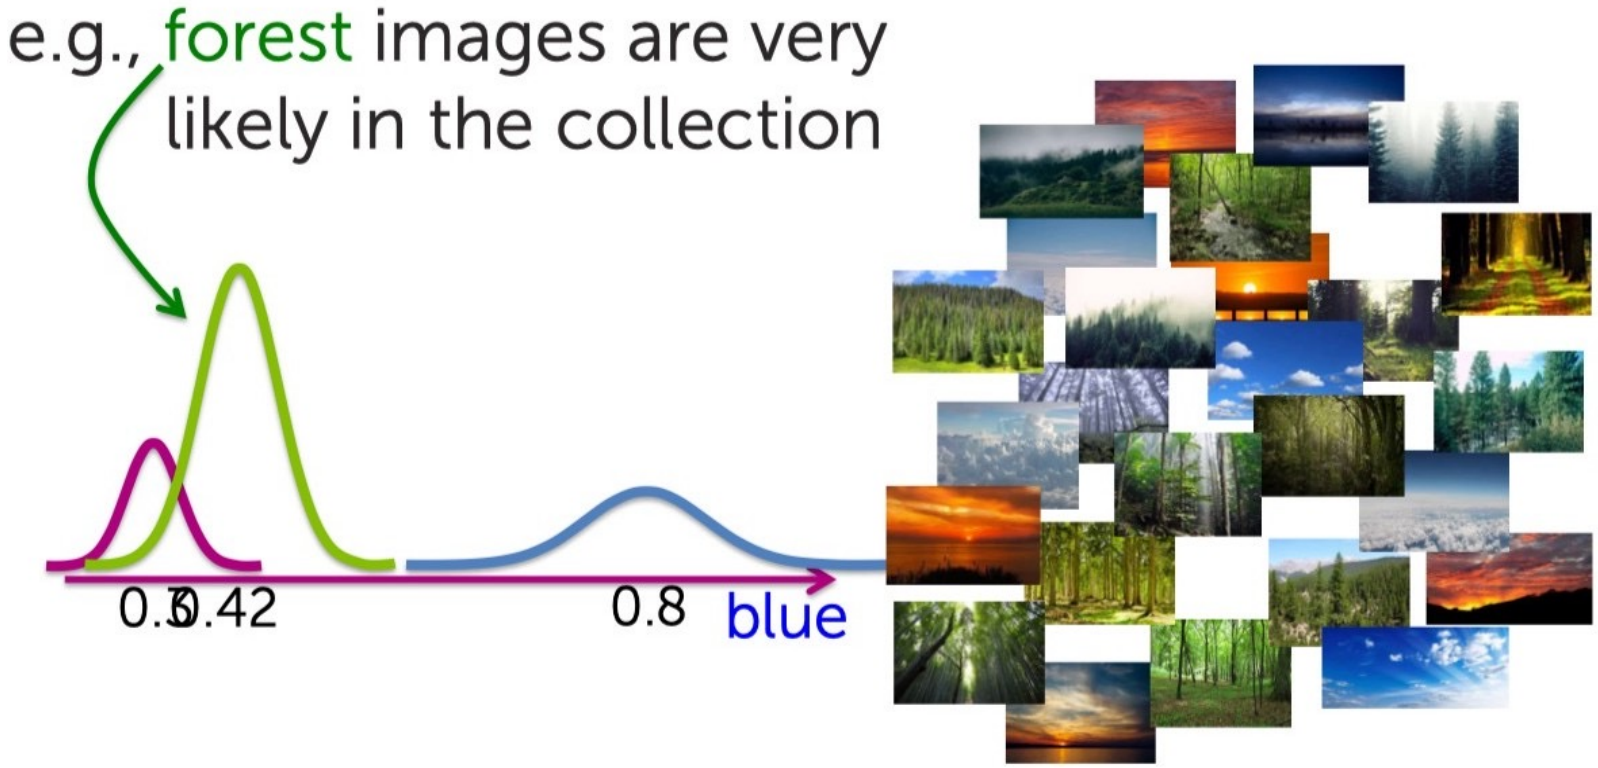


对无标注的数据如何建模?



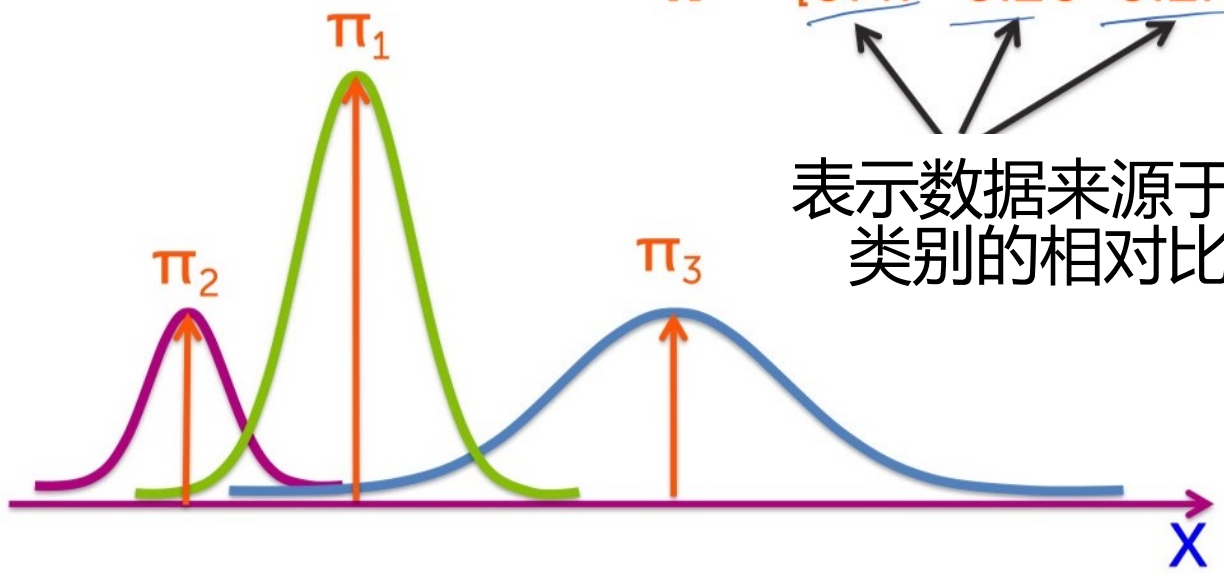


如果图片类型不是同等表示的，该如何建模?



加权高斯分布的结合

- 为每一个高斯分布，添加一个权重π_k



$\pi_1 \quad \pi_2 \quad \pi_3$

$\boldsymbol{\pi} = [0.47 \quad 0.26 \quad 0.27]$

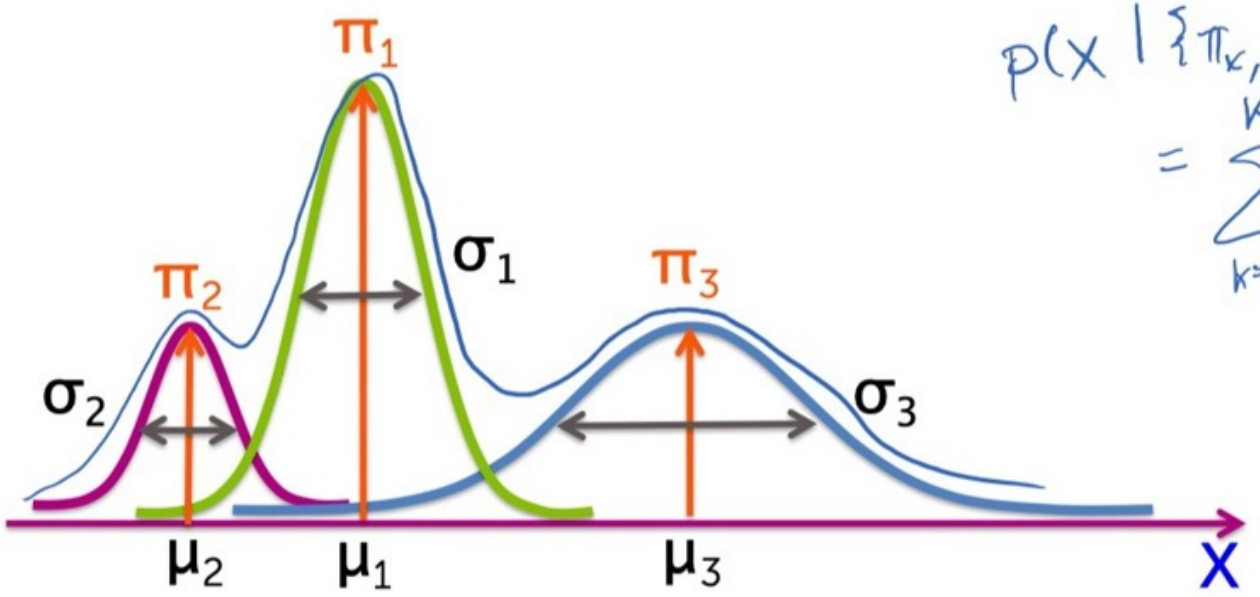
表示数据来源于每个类别的相对比例

$$0 \le \pi_k \le 1$$

$$\sum_{k=1}^{K} \pi_k = 1$$

高斯混合建模（1维数据）

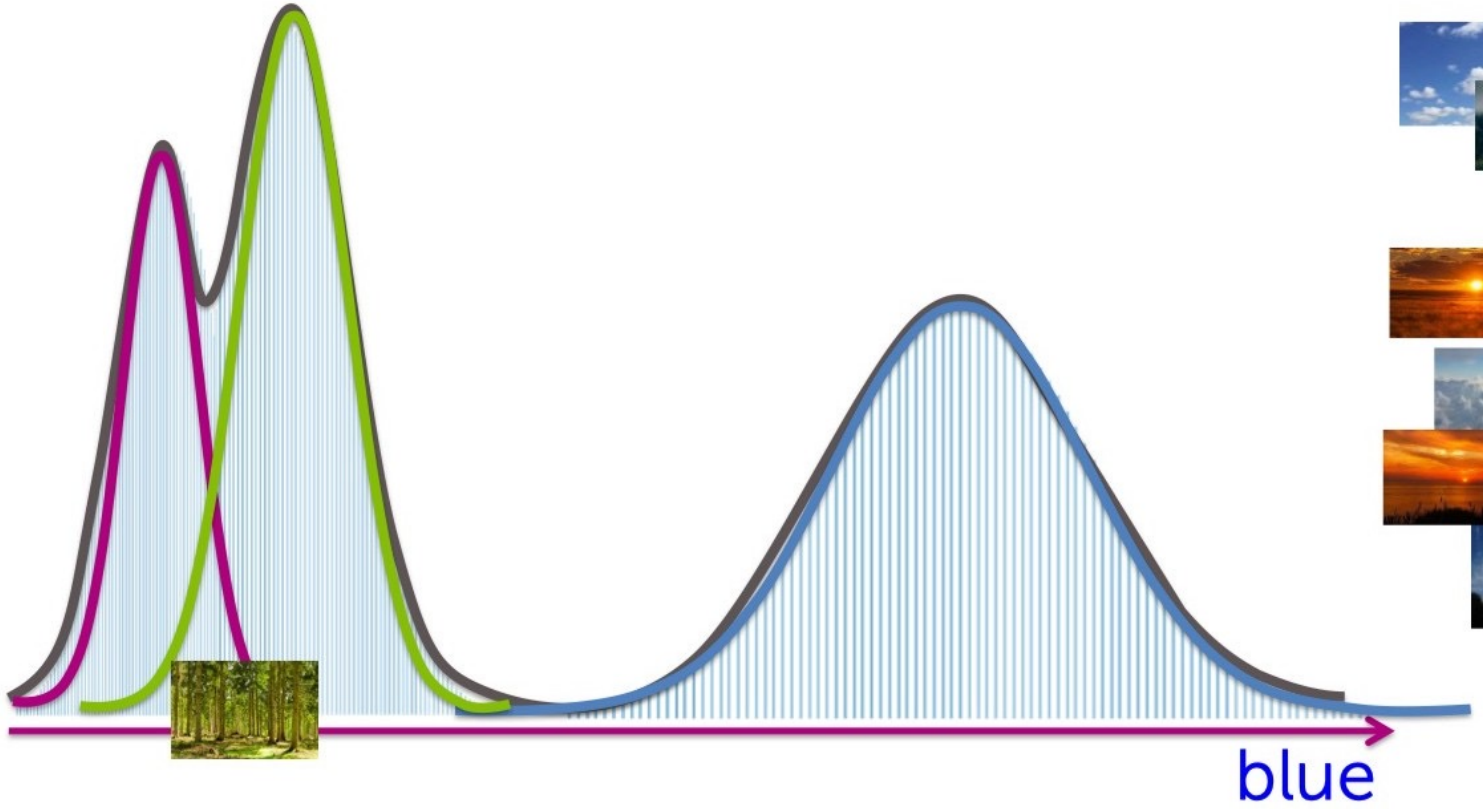
- 每一个高斯分布表示一个独特的聚类簇
  - $\{\pi_k, \mu_k, \sigma_k^2\}$



$$p(x \mid \{\pi_k, \mu_k, \sigma_k^2\}) = \sum_{k=1}^{K} \pi_k N(x \mid \mu_k, \sigma_k^2)$$

所有图的分布

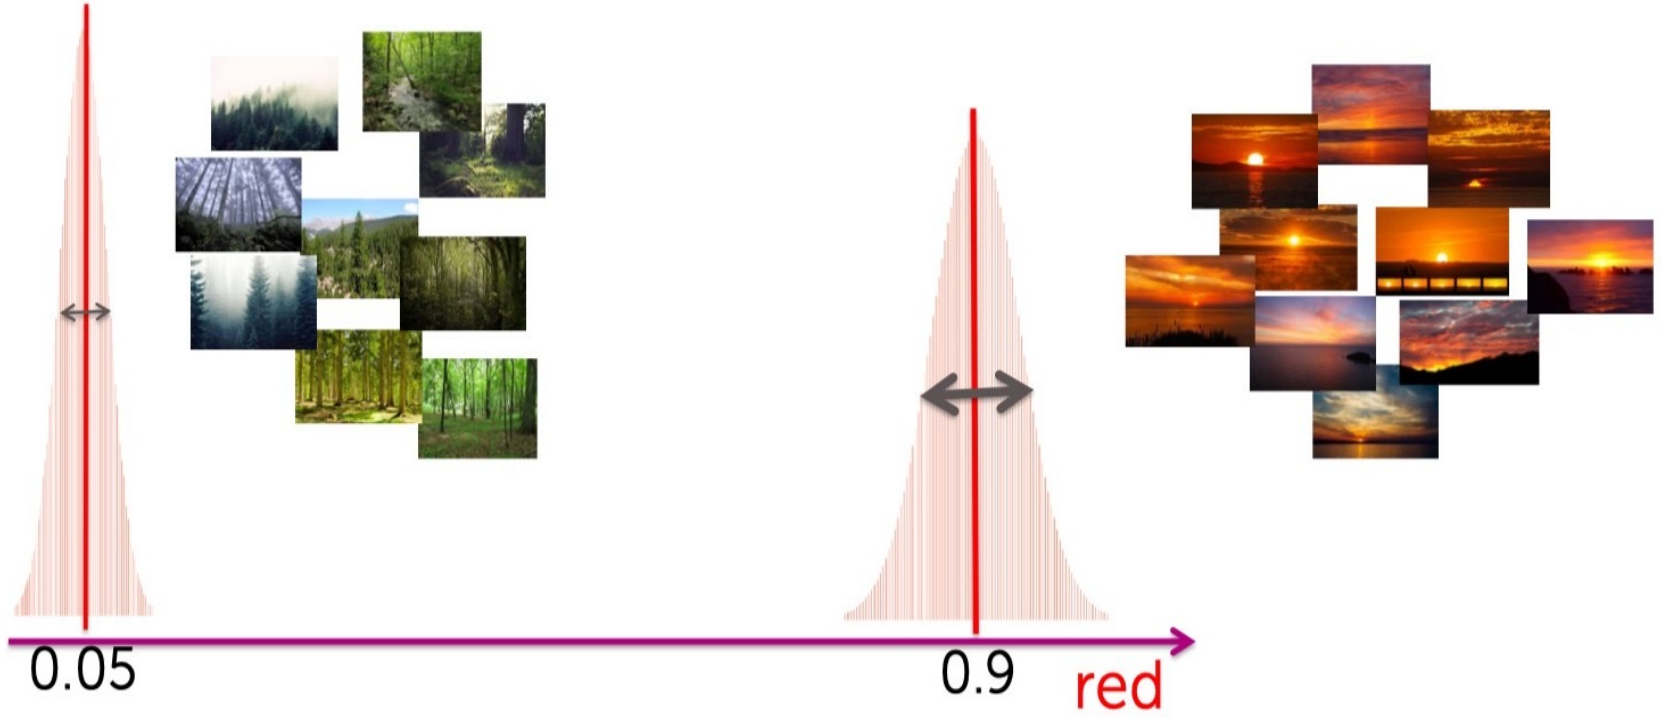
- 如果一个图片无法从前两个高斯分布中分别出来。





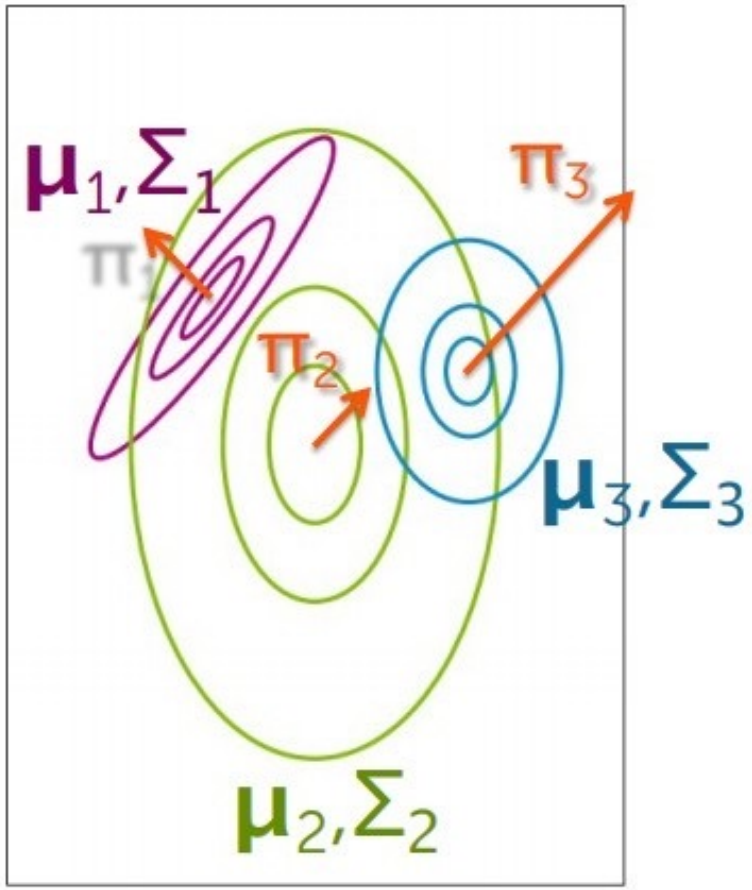
可以从其他维度上分辨出来

- 再次聚焦于红色维度



高斯混合（一般情况）

- 每个混合成分代表一个由以下参数指定的独特聚类
  - $\{\pi_k, \mu_k, \Sigma_k\}$
  - $p(x|\{\pi_k, \mu_k, \Sigma_k\}) = \sum_{k=1}^{K} \pi_k \, N(x|\mu_k, \Sigma_k)$



高斯混合模型

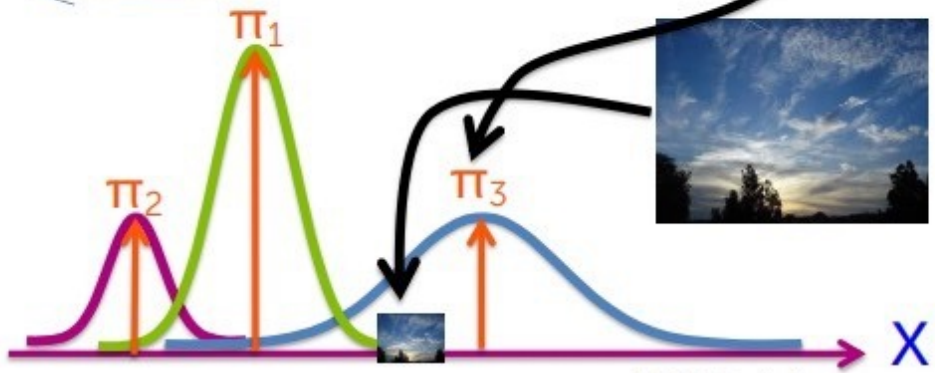
Without observing the image content, what's the probability it's from cluster k? (e.g., prob. of seeing "clouds" image)

$$p(z_i = k) = \pi_k$$

not cond. x_i

Given observation $\mathbf{x}_i$ is from cluster k, what's the likelihood of seeing $\mathbf{x}_i$? (e.g., just look at distribution for "clouds")

$$p(x_i \mid z_i = k, \mu_k, \Sigma_k) = N(x_i \mid \mu_k, \Sigma_k)$$



混合模型总结

- 解释如何使用混合模型（mixture models）来理解基于概率的聚类方法
- 描述模型的参数
- 说明软分配（soft assignments）的作用及其含义
- 比较并对比高斯混合模型（mixtures of Gaussians）与K-means聚类

Questions



2026秋AI&ML
群号: 1109611031